DIGITALHOUSE CLASE EN VIVO 3

ARCA | AGENCIA DE RECAUDACIÓN Y CONTROL ADUANERO

Estadística y Python aplicado

Clase en vivo 3 · 120 minutos

Programa Integral de Analista de Datos (Data Analyst) — ARCA

Escaneá el QR para registrar tu asistencia

Me presento...

1. Directora General en The eLabs: transformación digital e integración de IA.
2. Host del podcast Hack The Future: estrategia y liderazgo, no solo algoritmos.
3. Docente en la Maestría en Ciencia de Datos (Univ. Austral), ITBA y Di Tella.



Apasionada por aplicar IA para mejorar la productividad y las decisiones.

Lo que dejó la clase 2

1 Una pieza reutilizable

Una consulta útil se vuelve una función con nombre.

2 Se prueba con casos

Tres pruebas antes de confiar.

3 Equivalencia

Mismas filas antes y después de optimizar.

4 Se mide, no se promete

El costo se observa en el plan.

De la clase 2 nos llevamos una forma de comprobar antes de creer.

Qué vamos a lograr hoy

PROPÓSITO

Explorar Mercado Sur con Pandas y sostener una interpretación con medidas, controles y una visualización.

RESULTADO OBSERVABLE

Notebook con cinco controles, una visualización, un hallazgo y una limitación.

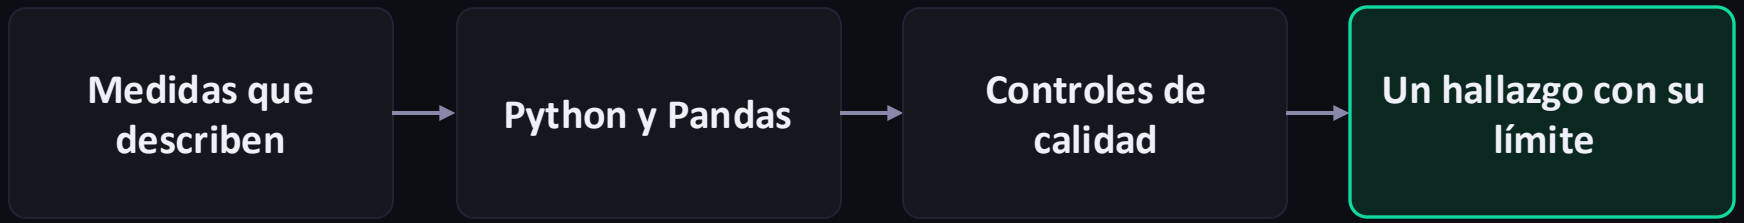
1 · Repaso estadístico con código

2 · Base de Python y Pandas

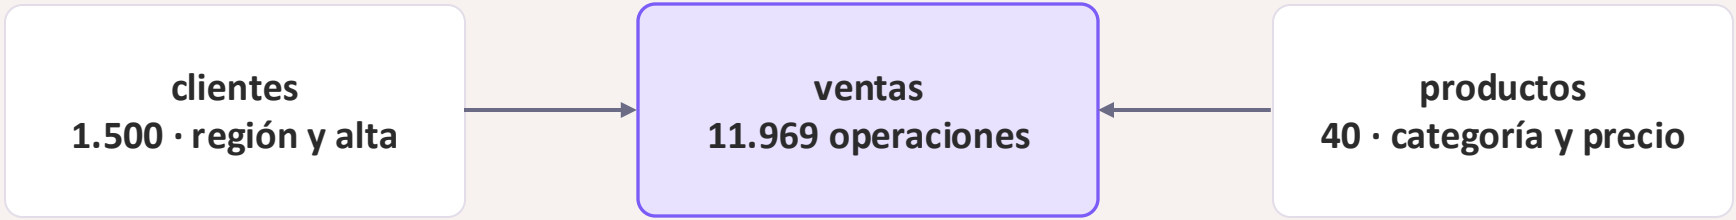
3 · Actividad de grupo

La pregunta de la clase

¿La experiencia del canal web empeoró, o cambió la composición de clientes y operaciones observadas?



Mercado Sur



Facturación realizada

Solo operaciones completadas.

Recurrente

Al menos dos operaciones completadas.

Satisfacción

Puede faltar: se analiza, no se reemplaza.

Describir una columna de números

1 El centro

Media, mediana y moda: ¿cuál es el valor típico?

2 La dispersión

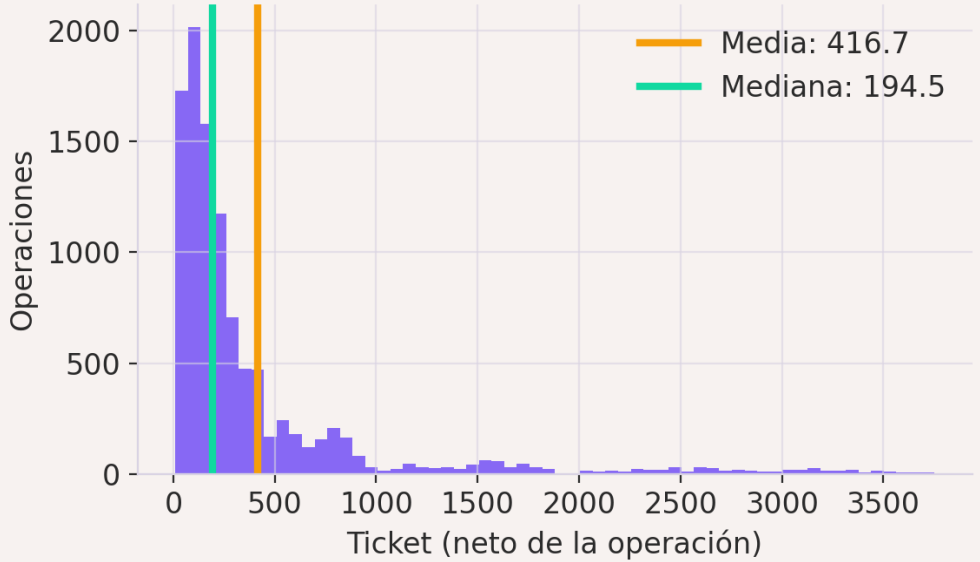
Desvío, cuartiles e IQR: ¿cuánto varía?

3 La forma

Asimetría y atípicos: ¿cómo se distribuye?

Ticket = unidades × precio × (1 – descuento), sobre operaciones completadas.

La media y la mediana no coinciden



Media 416,7: arrastrada por pocas operaciones muy grandes.

Mediana 194,5: la mitad está por debajo.

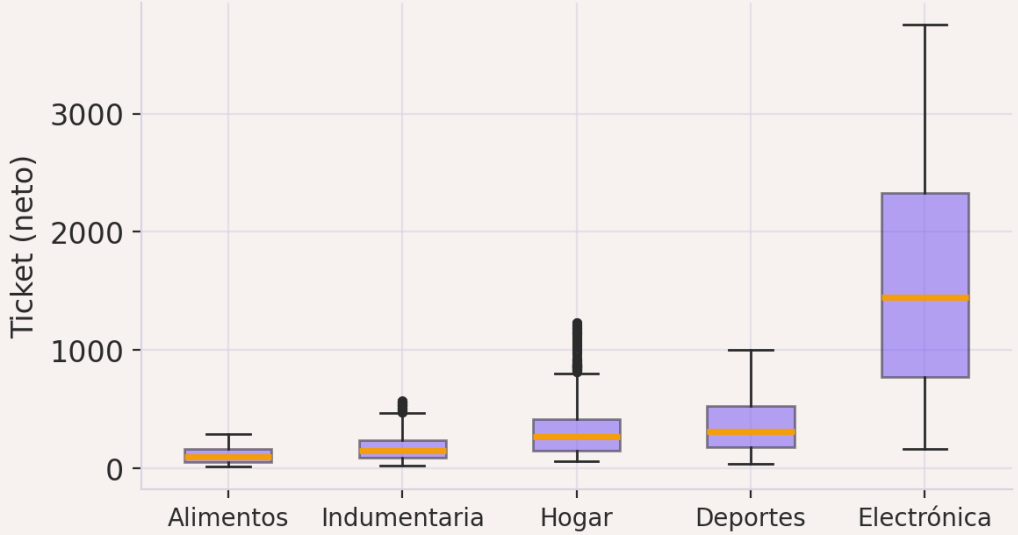
La moda de unidades es 1.

Dos números, dos historias

Medida	Valor	Qué dice
Rango	10,6 a 3.751,4	Hay de todo
Desvío estándar	624,1	1,5 veces la media
Q1 a Q3 (IQR 307,7)	96,5 a 404,3	El 50 % del medio
Percentil 99	3.197,3	El 1 % más caro

El rango muestra los extremos; el IQR, lo que es normal.

Los atípicos tienen explicación

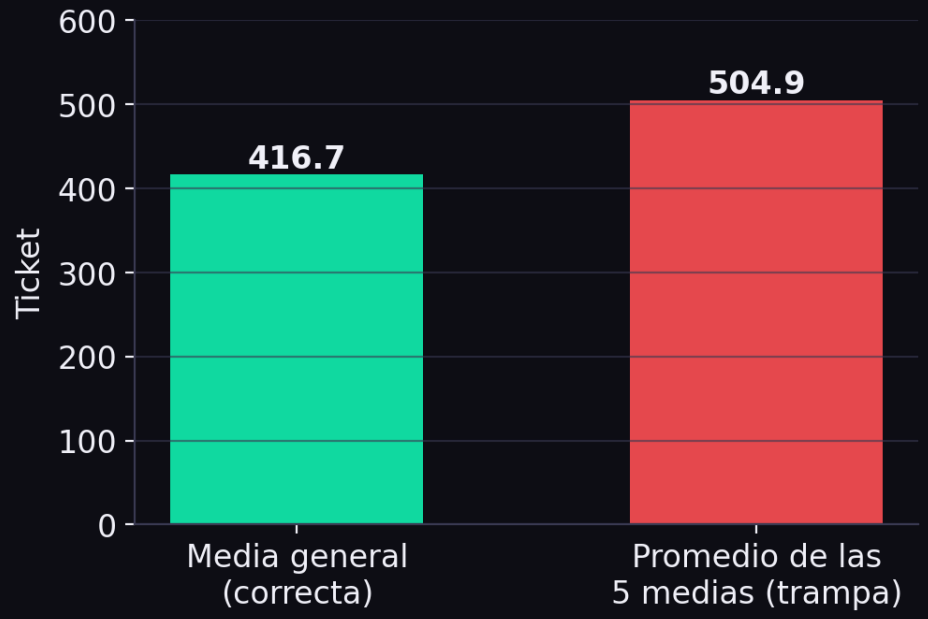


Asimetría 2,99: cola larga a la derecha.

1.137 atípicos (10,8 %), el 87 % de Electrónica.

Se investigan antes de borrarlos.

La trampa de promediar promedios

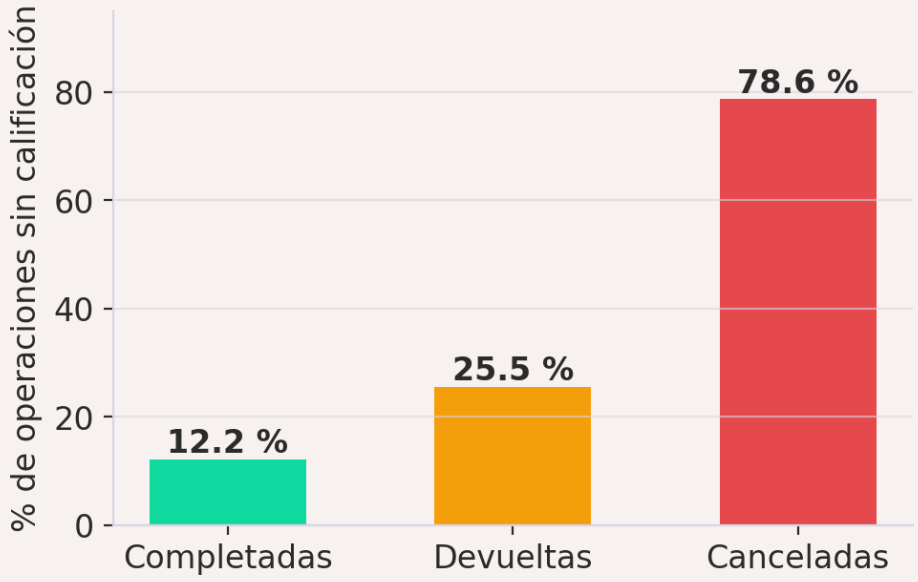


Cada grupo tiene un tamaño distinto.

Siempre se reporta el n de cada grupo.

Por canal, el año completo no muestra diferencias.

Un faltante no es un cero



SATISFACCIÓN MEDIA SEGÚN EL UNIVERSO

Todas las operaciones: 3,74

Solo completadas: 3,88

Faltante igual a 0: 3,12 (falso)

Reportá siempre qué universo usaste.

Asociación no es causalidad

Par de columnas	Correlación	Lectura
Precio unitario y neto	0,86	Fuerte, por cómo se calcula
Unidades y neto	0,05	Casi nula
Descuento y satisfacción	0,00	Sin relación lineal

Una correlación alta no demuestra causalidad; una nula solo descarta una relación en línea recta.

Python mínimo

Variables y tipos

```
nombre = "Mercado Sur"
clientes_n = 1500
descuento = 0.15
```

Listas y diccionarios

```
canales = ["web", "tienda"]
precios = {"Hogar": 300}
```

Condicionales y bucles

```
for cat, p in precios.items():
    if p > 200: ...
```

Funciones

```
def neto(unidades, precio, desc):
    return unidades * precio * (1 - desc)
```

La tabla como objeto

DataFrame
una tabla

→

Serie
una columna

→

Una operación
para todas las filas

Con bucle: fila por fila

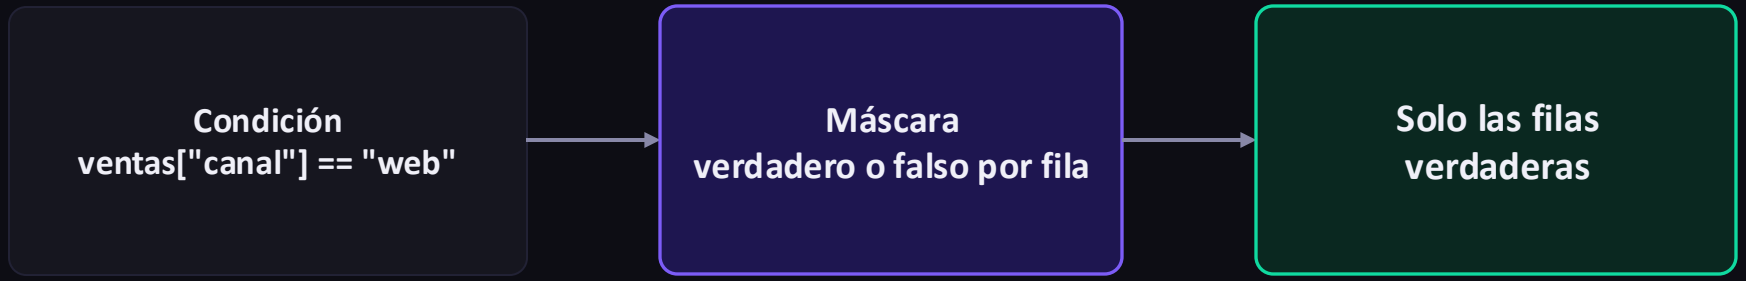
Vectorizado: la columna completa

Lo primero con una tabla

shape	dtypes	head()	describe()	value_counts()
Filas y columnas	Tipo de cada columna	Cómo se ve	Resumen numérico	Cuántas veces aparece cada valor

Siempre: forma, tipos, un vistazo y un resumen.

Una condición que filtra filas

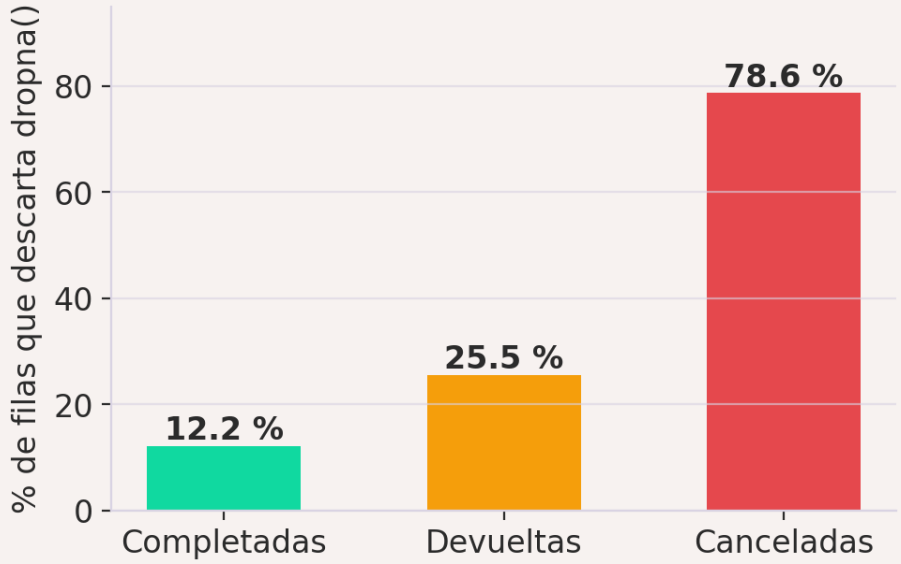


&
y: se cumplen las dos

|
o: alcanza con una

isin([...])
uno de varios valores

dropna() no es inocente



dropna() descarta 1.970 filas (16,5 %).

Pero el 79 % de las canceladas.

Un cero es un dato válido, no un faltante.

Crear, unir y agrupar

Crear columnas
mes, semestre, neto

→

Unir con merge
ventas + productos + clientes

→

Agrupar con groupby
una medida por grupo

Control del grano: 11.969 operaciones antes de unir y 11.969 después.

La pregunta elige el gráfico

1 Comparar categorías

Barras

2 Ver la evolución

Líneas

3 Ver la forma

Histograma

Un buen gráfico tiene título que diga qué muestra, ejes con nombre y una sola idea.

Tips y buenas prácticas

EN EL CÓDIGO

- •Trabajá sobre una copia y conservá el original.
- • Nombres que cuentan qué hay: ventas_web_s1, no df2.
- • Una transformación por celda, y mirá el resultado.
- • Controlá el grano después de cada merge.
- • Corré todo de arriba abajo antes de entregar.

EN EL ANÁLISIS

- • Primero la pregunta, el universo y la fórmula.
- • Predecí antes de correr y reportá el n.
- • Media y mediana juntas si hay cola larga.
- • Un gráfico, una idea, y un título que diga qué muestra.
- • Separá evidencia, interpretación y límite.

Reproducible: otra persona corre tu notebook y llega al mismo número.

Describir, limpiar, tratar y volver a analizar

1 · Primera descripción

Qué hay y qué falta.

→

2 · Limpieza

Decidir cada hallazgo y dejarlo escrito.

→

3 · Tratamiento

Aplicar sin inventar datos.

→

4 · Nuevo análisis

Volver a describir y comparar.

EN MERCADO SUR · ANTES (SIN CRITERIO) → DESPUÉS (CON CRITERIO)

Satisfacción media	Facturación	Ticket medio
3,12 → 3,88	5.045.995 → 4.373.544	421,6 → 416,7

El número que importa es el del nuevo análisis.

PRÁCTICA GUIADA

El perfil del dataset

Filas y claves	Duplicados	Faltantes	Rango temporal	Estados

Para cada hallazgo, una decisión explícita: qué hacemos y por qué.

Todos los equipos trabajan sobre los mismos datos y el mismo perfil.

Cinco controles de calidad

1	2	3	4	5
Grano	**Claves**	**Fechas**	**Estados**	**Valores**
id_venta único	cliente y producto existen	todas dentro de 2025	solo tres estados válidos	descuento de 0 a 1; unidades positivas

Cada control dice qué verifica y si pasó.

Comparar decisiones, no solo resultados

1 ¿Qué supuesto explica la diferencia?

Dos decisiones razonables pueden dar números distintos.

2 Un error frecuente

Se compara una salida incorrecta con una controlada.

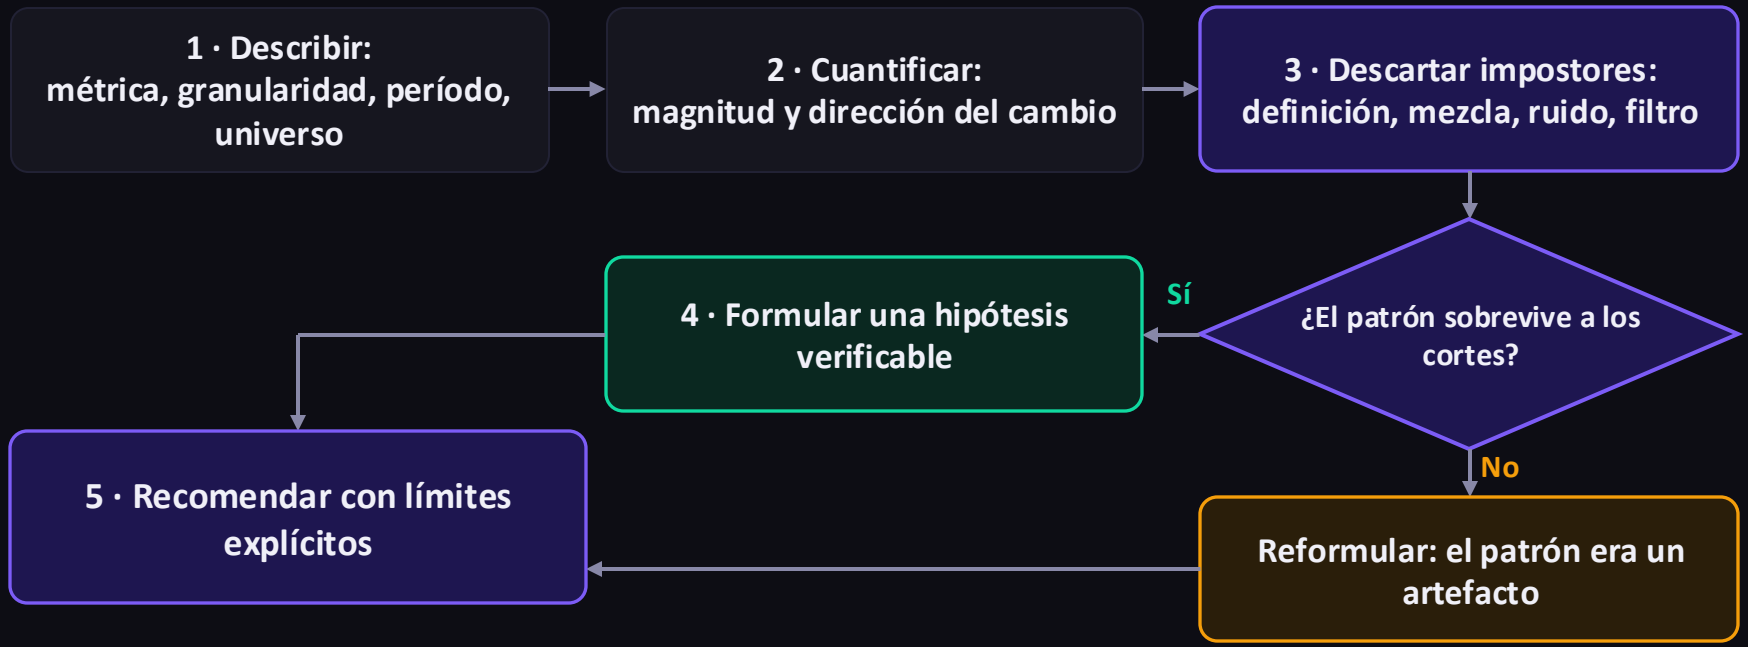
3 Solo el paso que cambia

Se rehace lo que cambia la conclusión.

Seis errores que cambian la conclusión

Error	Qué pasa	Cómo se evita
dropna() indiscriminado	Descarta 1.970 filas, el 79 % de las canceladas	Analizar el faltante antes de borrar
Confundir cero con faltante	Satisfacción con 0: la media baja de 3,74 a 3,12	Un cero es un dato; un faltante es una ausencia
Promediar promedios	Da 504,9 en lugar de 416,7	Promedio ponderado y el n de cada grupo
Graficar antes de validar	El gráfico se arma sobre tipos o universo equivocados	Validar tipos y universo primero
Afirmar causalidad	Una asociación no dice por qué pasó	Describir y declarar el límite
No fijar el universo	Contar todo sobrestima la facturación en 15,4 %	Declarar el universo: solo completadas

El procedimiento de abordaje de datos



El criterio decide cada paso: la herramienta solo calcula.

ACTIVIDAD DE GRUPO

Desafío por equipos

Conduce

Ordena el trabajo y la discusión.

Ejecuta

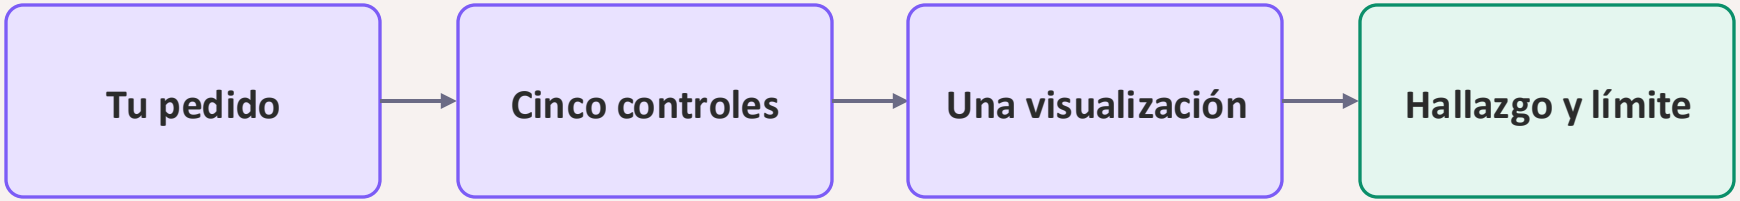
Escribe y corre el código.

Valida

Controla universo y tamaños.

Presenta

Cuenta el hallazgo y su límite.



Los roles rotan. Todos usan los mismos datos.

Siete equipos, siete ángulos

1 El ticket

Media y mediana, con n.

2 La recompra

Compradores recurrentes.

3 La satisfacción

Con faltantes, sin imputar.

4 Los estados

Dónde se concentra el cambio.

5 La composición

Mezcla por región y categoría.

6 La frecuencia

Operaciones por comprador.

7 La tienda

Grupo de comparación.

Seis comparan semestres del canal web; el siete usa la tienda como comparación.

El criterio en cada paso

Paso	La pregunta de criterio	Qué se muestra	Al recorrer
1 · Describir	¿Qué mido y sobre quién?	Métrica, granularidad, período y universo	¿Cuál es el universo?
2 · Cuantificar	¿Cuánto cambió y en qué dirección?	Diferencia y variación, con el n	—
3 · Impostores	¿Puede ser un artefacto?	Definición, mezcla, ruido y filtro	¿Cómo lo validaron?
Cortes	¿Se repite en los subgrupos?	El cambio dentro de cada grupo	¿Cómo lo validaron?
4 · Hipótesis	¿Qué lo explicaría y cómo lo verifico?	Algo que se pueda contrastar	—
5 · Recomendar	¿Qué habilita y qué no puedo afirmar?	Recomendación con límites	¿Qué decisión habilita? ¿Qué no pueden afirmar?

No se resuelve la tarea: se señala el criterio para elegir el paso siguiente.

Cómo se reconoce un resultado logrado

1. Responde la pregunta definida, no una más fácil
2. Hace visible universo, período, grano y regla
3. Ruta reproducible, de los datos a la conclusión
4. Una validación y una limitación
5. Una decisión proporcional a la evidencia

Presentar, preguntar y devolver

El equipo presenta

El hallazgo, el número y el límite.

→

El revisor pregunta

Una pregunta de método y una de negocio.

→

Se registra

Una decisión sólida y una brecha corregible.

Una brecha que se puede corregir sin rehacer todo el trabajo.

Un kit para empezar con datos

1 · Describir	2 · Cuantificar	3 · Impostores	Cortes	Todo junto
reporte_inicial(tabla)	cuantificar_cambio(...)	descartar_impostores(...)	cortes(...)	procedimiento(...)
Todas las medidas, juntas	Magnitud y dirección	Definición, mezcla, ruido y filtro	¿Sobrevive en los subgrupos?	Pasos 1 a 3 y cortes

El kit calcula; el criterio decide.

Qué me llevo y qué dejo escrito

CUATRO IDEAS PARA LLEVARSE

1. **Mediana y media cuentan distinto**
   Con colas largas, la mediana.
2. **Un faltante no es un cero**
   Se analiza, no se borra.
3. **Reportá el n y el universo**
   Y no promedies promedios.
4. **Controlá antes de afirmar**
   Cinco controles y un límite.

TICKET DE SALIDA · UNA FRASE POR CADA UNO

Qué voy a repetir

Lo que mejor funcionó.

Qué voy a verificar

Lo que todavía no controlé.

Qué voy a dejar de hacer

Un hábito que sesga.

LO QUE VIENE

Hacia la clase 4

Hoy: un hallazgo con su límite

→

Clase 4: del hallazgo al dashboard

- **Proceso de análisis**
- **Apache Superset**

Eso introduce la clase 4: proceso de análisis y Apache Superset.

DIGITALHOUSE

ARCA | AGENCIA DE RECAUDACIÓN Y CONTROL ADUANERO

PREGUNTAS Y RESPUESTAS

Q&A

¿Qué dudas, casos o ideas quedaron?

¡Muchas gracias!

Laura Sol Franco · Digital House

Programa Integral de Analista de Datos (Data Analyst) — ARCA