DIGITALHOUSE CLASE EN VIVO 1

ARCA | AGENCIA DE RECAUDACIÓN Y CONTROL ADUANERO

Arquitectura y Modelado de Datos

Clase en vivo 1 · 120 minutos

Programa de Arquitectura de Datos y Orquestación — ARCA



Escaneá el QR para registrar tu asistencia

Me presento...

1. Directora General en The eLabs: transformación digital e integración de IA.
2. Host del podcast Hack The Future: estrategia y liderazgo, no solo algoritmos.
3. Docente en la Maestría en Ciencia de Datos (Univ. Austral), ITBA y Di Tella.



Apasionada por aplicar IA para mejorar la productividad y las decisiones.

Qué vamos a lograr hoy

PROPÓSITO

Diseñar y defender una arquitectura y un modelo dimensional para nuestro caso, NexoServicios.

RESULTADO OBSERVABLE

Diagrama de arquitectura y modelo dimensional con grano explícito.

Cada equipo defiende una decisión.

→ Repasamos lo mínimo de los módulos 1 y 2 y lo aplicamos al caso.

Agenda de la clase

Momento	Actividad	Evidencia
Contexto del proyecto	Qué se entrega y cómo se evalúa el proyecto final	Expectativas claras
Nivelación	Módulos 1 y 2, errores frecuentes y seis preguntas antes de diagramar	Dudas aclaradas
Encuadre	Cada equipo nombra una decisión difícil y su riesgo	Hipótesis inicial escrita
Diagnóstico	El grupo formula preguntas sobre el caso	Lista priorizada de preguntas
Demo guiada	Diseño paso a paso: decisión, arquitectura, ritmo, modelo y controles	Ejemplo anotado
Ejercicio en equipos	Cada equipo completa el registro de decisión de arquitectura	Registro de decisión completo
Revisión cruzada y puesta en común	Revisión con checklist y presentación de dos o tres equipos	Dos hallazgos y una defensa breve
Cierre	Key takeaways y espacio de preguntas (Q&A)	Una frase por persona

El proyecto integrador

Diseñar y defender una solución de datos de punta a punta para NexoServicios.

SEIS CLASES EN VIVO, UN SOLO PROYECTO

1 HOY	2	3	4	5	6
Arquitectura y modelado	Procesamiento con PL/SQL	Pipelines con Apache NiFi	Orquestación y gobierno	MLOps y plataformas	Proyecto final y cierre

Hoy aportamos: el mapa de fuentes, capas y contratos, y el modelo dimensional del caso.

Qué se entrega

1. Problema, alcance, supuestos y restricciones
2. Diagrama de arquitectura: de la fuente al consumo
3. Modelo conceptual y dimensional, con grano explícito
4. Ejemplo PL/SQL con contrato, errores y prueba
5. Ingestión NiFi y orquestación Airflow, con observabilidad
6. Matriz de gobierno: responsables, controles y acciones
7. Controles de seguridad y estrategia de metadatos
8. Si hay ML: trazabilidad, promoción, monitoreo y rollback
9. Registro de decisiones y alternativas (plantilla de hoy)
10. **Presentación ejecutiva de 8 min y defensa de 7 min**

La defensa se sostiene con artefactos/ppts, sin demo en vivo.

Cómo se reconoce un proyecto logrado

- ✓ La necesidad de negocio se conecta con cada decisión
- ✓ Los flujos pueden reconstruirse
- ✓ Los controles tienen responsables y acciones
- ✓ Las pruebas muestran cómo se detectan y recuperan fallas
- ✓ La defensa reconoce límites y riesgos reales

REGLAS DEL JUEGO

Cada componente declara su nivel: ejecutado, simulado o especificado

Datos sintéticos, sin credenciales

Lo que el caso no define es un supuesto declarado

Se evalúan arquitectura, operación, gobierno, seguridad, MLOps y comunicación

Diseñar para trascender el momento

PUNTO DE PARTIDA: FLEXIBILIDAD

Las herramientas cambian:

Se diseña en capas con responsabilidades claras, no en productos.

Gobierno

Quién responde por cada dato, qué calidad se exige y quién accede.

Madurez

Se avanza por etapas, de lo básico a lo gobernado.

Sobre esa base sumamos los componentes de la plataforma.

Cinco capas y un gobierno que las atraviesa



Fuentes

De dónde nace el dato: sistemas, archivos, APIs.



Ingesta

Cómo entra al ecosistema: carga por lotes o continua.



Almacenamiento

Dónde se guarda, en capas, hasta que se usa.



Procesamiento

Cómo se limpia, se transforma y se le aplican reglas.



Consumo

Quién lo usa: tableros, alertas, analistas, modelos.

Gobierno de datos: responsabilidad · calidad · seguridad

Lake, warehouse, lakehouse y dominios

Data lake

QUÉ ES

Guarda los datos en su formato original, estructurados o no.

SIRVE PARA

Explorar y conservar todo; datos nuevos o variados.

CUIDADO CON

Sin gobierno se vuelve un pantano.

Data warehouse

QUÉ ES

Datos estructurados y modelados, con esquema previo.

SIRVE PARA

Reportes e indicadores confiables y rápidos.

CUIDADO CON

Es menos flexible para datos nuevos o no estructurados.

Lakehouse

QUÉ ES

Une la flexibilidad del lake con las capacidades del warehouse.

SIRVE PARA

Cubrir exploración y reportes sin duplicar los datos.

CUIDADO CON

Requiere madurez y gobierno para sostenerse.

Dominios por servicio

QUÉ ES

Cada dominio es dueño de sus datos (tipo data mesh).

SIRVE PARA

Organizaciones grandes, con muchos equipos y servicios.

CUIDADO CON

Es un modelo organizativo, no una tecnología.

No son excluyentes: se combinan según madurez y tamaño.

Dos nombres para la misma idea

BRONZE · SILVER · GOLD

Bronze

Datos tal como llegan, sin transformar.

Silver

Depurados, validados y unificados.

Gold

Listos para el negocio: métricas e indicadores.

≈ ≈ ≈

RAW · TRUSTED · VIEW

Raw

Crudo: copia fiel del origen.

Trusted

Confiable: validado, con calidad medida.

View

Vistas para consumo: lo que usa cada audiencia.

Cada capa necesita un contrato: qué contiene, quién la mantiene y qué calidad garantiza.

Dos decisiones que cambian la arquitectura

¿CUÁNDO LLEGA EL DATO?

Lotes — Cargas por tandas (horas o días). Simple y barato de operar.

Frecuente — Ciclos cortos, cada pocos minutos. Punto medio.

Continuo — Eventos al instante: lo más inmediato y complejo.

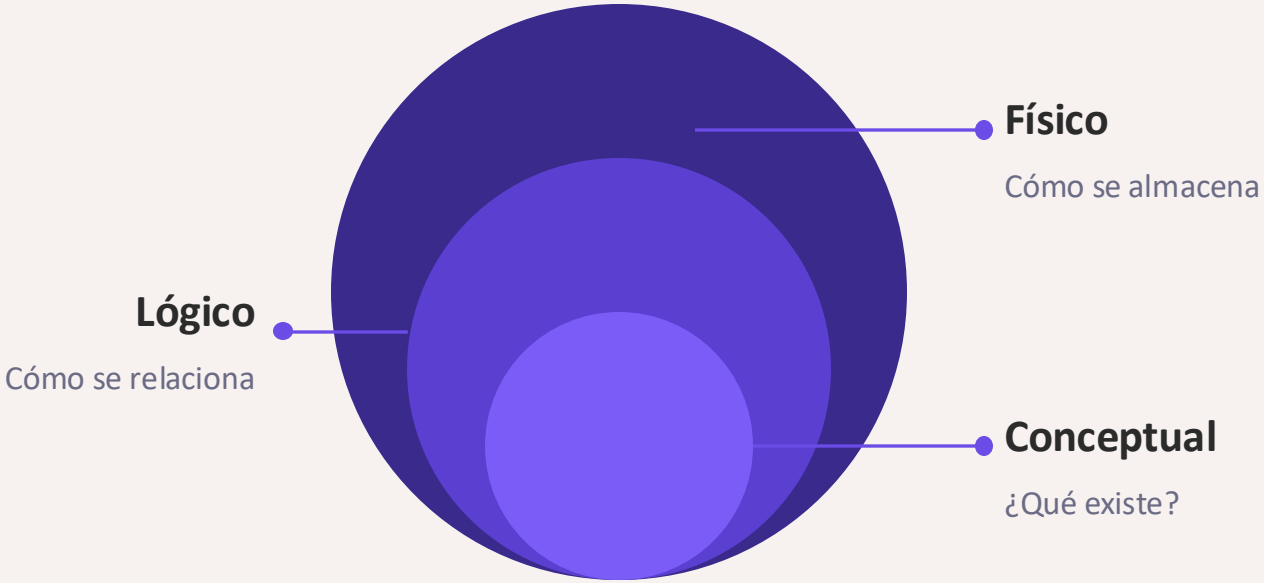
¿DÓNDE SE TRANSFORMA?

ETL — Transforma antes de cargar: destino limpio, menos flexible.

ELT — Carga lo crudo y transforma en destino: flexible, exige gobierno.

El ritmo lo define la decisión, no la tecnología disponible.

Los tres niveles del modelado



Cada nivel responde una pregunta distinta. Confundirlos hace que los modelos no escalen.

Tipos de entidad

Toda entidad es de uno de tres tipos: reconocerlo define su clave y su granularidad.

Maestras

Objetos estables del negocio que persisten en el tiempo.

NEXOSERVICIOS

- Cliente
- Producto
- Punto de servicio

Transaccionales

Registran hechos que ocurren en un momento determinado.

NEXOSERVICIOS

- Contrato
- Pago
- Reclamo

De referencia

Catálogos controlados que clasifican otras entidades.

NEXOSERVICIOS

- TipoDocumento
- EstadoContrato
- Canal

Hechos, dimensiones y grano

Hecho

Lo que medimos: importes, cantidades, tiempos.

Ej.: el monto de un pago

Dimensión

El contexto para cortar y filtrar: quién, qué, cuándo, dónde.

Ej.: cliente, punto de servicio, fecha

Grano

Qué representa una fila de la tabla de hechos.

Ej.: una fila por pago

El grano se declara primero: define qué se mide y cómo se agrega.

Señales de alerta y cómo mitigarlas

Señal	Cómo se ve	Mitigante
Modelar por pantalla	Las entidades reflejan formularios, no conceptos de negocio	Volver a identificar las entidades genuinamente relevantes
Clave de origen como clave empresarial	Cliente duplicado por sistema; integración fallida	Clave sustituta, con mapeo a las claves de origen
Estado actual mezclado con historia	No se pueden auditar situaciones pasadas	Separar estado y cambios, con vigencia explícita
Columnas sin semántica	Campos como campo_libre_1 o dato_extra	Modelar ese atributo como parte del negocio y nombrarlo
Grano no declarado o mezclado	Reportes inconsistentes y medidas duplicadas	Declarar el grano; separar granos en tablas
SCD Tipo 1 cuando se necesita historia	El pasado “cambia” en los reportes históricos	Usar SCD2 en los atributos históricos

Seis preguntas antes de diagramar

1. ¿Qué decisión se toma con estos datos y quién la toma?
2. ¿Qué cambia si el dato llega en minutos, horas o días?
3. ¿Cuánto volumen y variedad tiene la fuente?
4. ¿Quién consume: reportes, APIs, modelos, apps?
5. ¿Qué restricciones existen (presupuesto, legales, permisos, trazabilidad)?
6. ¿Tiene el equipo la capacidad para operar esta arquitectura toda la semana?

Si no podés responder una, esa es tu primera pregunta abierta.

Encuadre: una pregunta incómoda

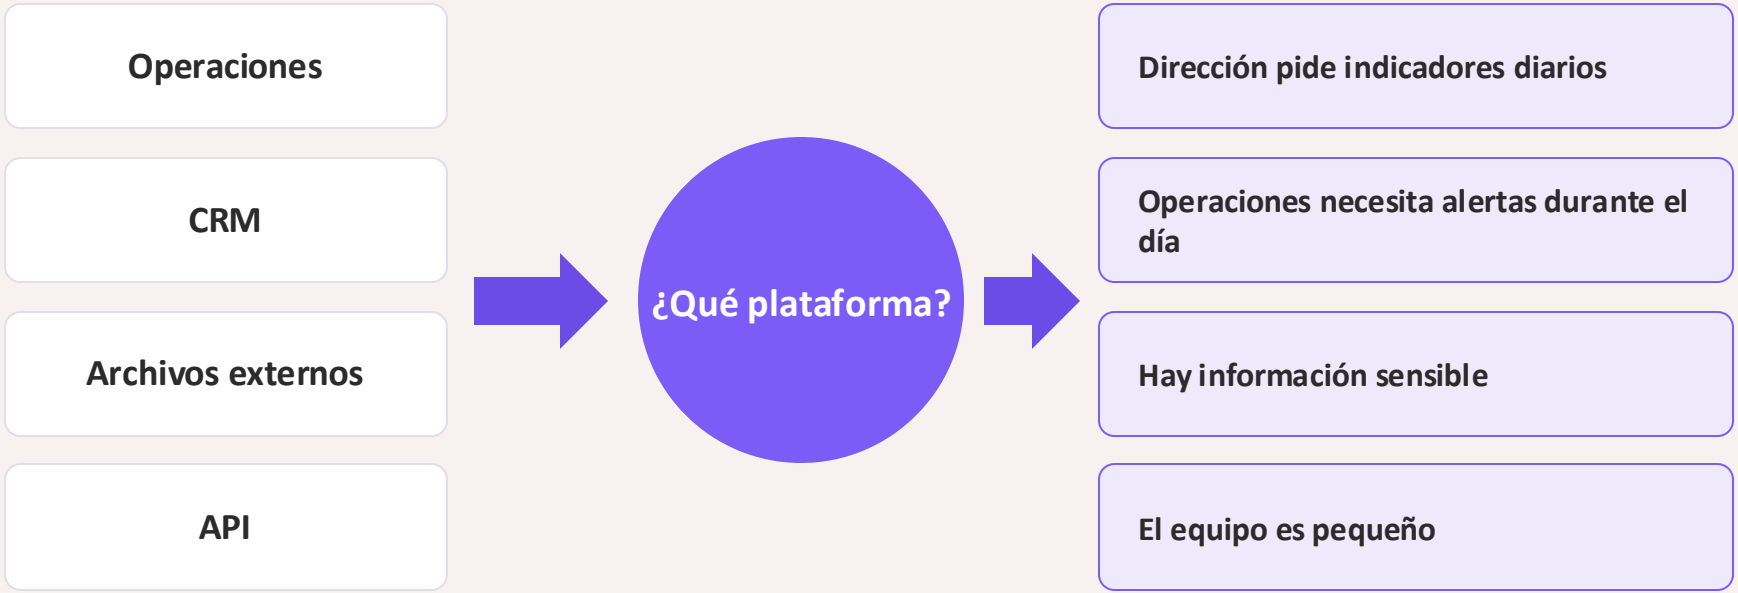
¿Qué decisión de tu propuesta sería más costosa de revertir dentro de un año?

Respondé en una frase. Después las agrupamos por:

- **Costo**
- **Seguridad**
- **Calidad**
- **Operación**
- **Dependencia tecnológica**

Objetivo: una decisión defendible, con restricciones explícitas.

El caso: NexoServicios



Incompleta a propósito: detectar qué falta es parte del trabajo.

Diagnóstico: hasta siete preguntas

Formulen hasta siete preguntas que deban responderse antes de implementar.

Yo las anoto. Buscamos supuestos, dependencias y datos faltantes.

AL MENOS UNA PREGUNTA SOBRE:

1. Volumen o latencia
2. Seguridad
3. Calidad
4. Recuperación
5. Responsabilidad humana

El método que voy a repetir

1. Nombrá la restricción comprobable
2. Compará dos opciones posibles
3. Elegí una y declará el costo que aceptás
4. Definí un control que detecte el fallo
5. Indicá qué evidencia permitiría aprobar o rechazar

En cada decisión recorremos estos cinco pasos. Después, les toca a ustedes.

Primero, qué problema resolvemos

Integrar cuatro fuentes para dar indicadores diarios y alertas del día, cuidando lo sensible con un equipo pequeño.

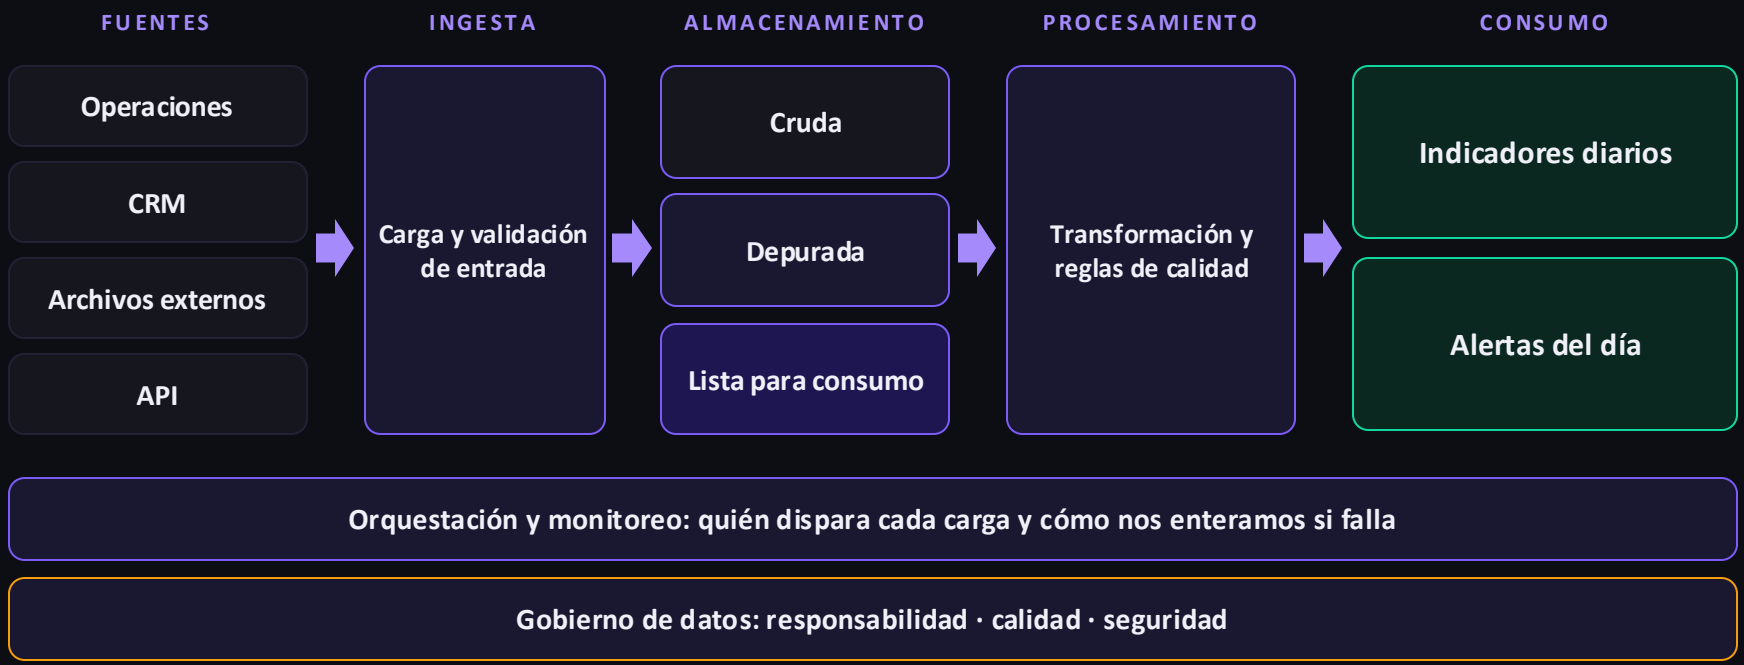
ENTRA

- Indicadores diarios (Dirección)
- Alertas del día (Operaciones)
- Las cuatro fuentes del caso

QUEDA FUERA (POR AHORA)

Volumen, permisos y disponibilidad no declarados: quedan como preguntas abiertas.

Del dato al indicador



Ejemplo anotado: el ritmo del dato

1 Restricción	Indicadores una vez por día; alertas durante el día.
2 Opciones	A) Todo en tiempo real. B) Carga diaria + ciclos frecuentes solo para alertas.
3 Trade-off	Elijo B: acepto dos ritmos de carga para no sostener tiempo real sin uso.
4 Control	Chequeo de frescura: si el dato no llega a tiempo, se avisa a una persona.
5 Evidencia	Registro de cada carga (hora, volumen, resultado) para aprobar o rechazar.

La plantilla: registro de decisión

CONTEXTO Y DECISIÓN

Problema que se resuelve: indicadores diarios y alertas del día

Decisión que habilita: ritmo de carga de cada consumo

Restricciones verificadas: Dirección, una vez por día; Operaciones, durante el día

Supuestos por confirmar: hora de llegada y volumen

OPCIONES

A · Todo en tiempo real

Beneficio: datos inmediatos

Costo o riesgo: complejidad para un equipo pequeño

Evidencia necesaria: costo de operarlo

B · Diario + ciclos frecuentes

Beneficio: simple, cubre ambos usos

Costo o riesgo: dos ritmos de carga

Evidencia necesaria: registro de cargas

DECISIÓN ELEGIDA

Elección: B

Trade-off aceptado: dos ritmos de carga

Control: chequeo de frescura con aviso

Señal para revisar esta decisión: alertas tardías

Responsable de revisión: rol de operación (a acordar)

Ejemplo ilustrativo: los valores son supuestos míos; el caso no los define.

¿Qué está mal en esta decisión?

DECISIÓN PROPUESTA

Procesar en tiempo real un indicador que se consulta una vez por día.

CONTROL PROPUESTO

Registrar el fallo en un log.

Hay dos problemas. ¿Los encuentran?

Dos minutos por equipo, después lo discutimos.

El grano primero



Entidades del caso; el grano y las dimensiones son supuestos que declaro y valido.

Detectar, contener y recuperar

DETECTAR

- Frescura: ¿llegó el dato del día?
- Volumen: ¿dentro de lo esperado?
- Reglas de negocio: ¿valores con sentido?

CONTENER

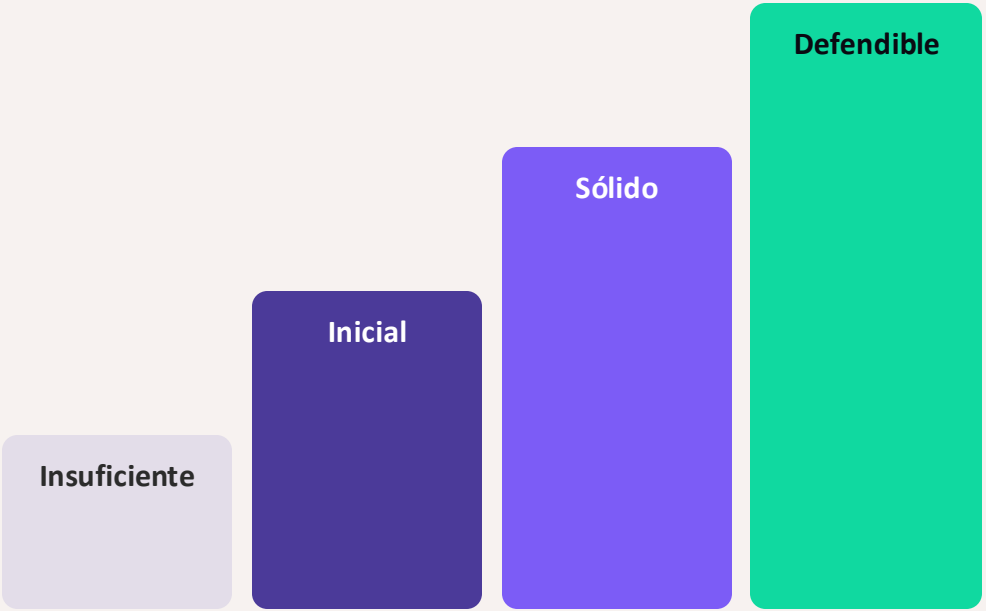
- No publicar si el control no pasa
- Aislar la carga fallida
- Acceso mínimo al dato sensible

RECUPERAR

- Reprocesar la carga del día
- Volver a la última versión buena
- Una persona decide la republicación

Monitorear no es recuperar: cada control tiene dueño y acción.

Cómo vamos a evaluar tu entrega



SE EVALÚA

- Trazabilidad entre problema y diseño
- Manejo de trade-offs
- Verificabilidad
- Operación segura
- Claridad de la defensa

Posible no es defendible: sin forma de validar y recuperar, queda en nivel inicial.

PARA TENER PRESENTE EN EL EJERCICIO

Errores frecuentes a evitar

- ✕ Dibujar productos sin responsabilidades ni flujos
- ✕ Confundir monitoreo con recuperación
- ✕ Definir calidad solo como “no hay nulos”
- ✕ Esconder decisiones humanas detrás de una automatización
- ✕ Suponer volumen, permisos o disponibilidad no declarados
- ✕ Elegir una herramienta antes de fijar el requisito

EJERCICIO · EQUIPOS DE 3 O 4 PERSONAS

Ahora ustedes: la plantilla, una decisión

ELIJAN UNA (SIN REPETIR ENTRE EQUIPOS)

Dato sensible

quién accede y cómo se protege

Calidad del dato

qué se mide y qué se hace si falla

Recuperación

qué pasa cuando una carga se cae

Alertas del día

qué dispara y quién actúa

ENTREGABLE

- Registro de decisión completo
- Opciones A y B, con evidencia
- Trade-off, control, señal de revisión y responsable

Revisión cruzada: checklist

- [ ] El problema está formulado como decisión y no como deseo
- [ ] Fuentes, transformaciones y consumidores identificables
- [ ] Los límites de seguridad y responsabilidad están visibles
- [ ] Existe un criterio de calidad medible
- [ ] Hay una estrategia de reintento, reproceso o rollback
- [ ] Hay evidencia suficiente para explicar qué ocurrió
- [ ] El costo o la complejidad aceptados están declarados

Elijan tres ítems: no hace falta recorrer los siete.

REVISIÓN EXPRESS

Dos hallazgos y una pregunta

ANTES DE PRESENTAR

Aceptá o rechazá cada observación y justificá. “Corregido” no alcanza.

Puesta en común: preguntas de debrief

1. ¿Qué decisión cambiaría si la latencia se redujera diez veces?
2. ¿Qué componente tiene mayor impacto ante una falla?
3. ¿Qué evidencia necesitaría alguien ajeno para reconstruir lo ocurrido?
4. ¿Qué control podría dar falsos positivos y cómo se administraría?
5. ¿Qué parte del diseño depende de algo todavía no confirmado?

Key Takeaways

1. **Diseñar para trascender el momento**

   Flexibilidad primero; el gobierno y la madurez la sostienen.

2. **Antes de diagramar, preguntar**

   Seis preguntas ordenan las decisiones.

3. **Cada decisión, cinco pasos**

   Restricción, opciones, trade-off, control y evidencia.

4. **Defendible es verificable**

   Un buen diseño se valida y se recupera, no solo se dibuja.

Tu decisión más sólida, el riesgo abierto y el próximo experimento.

DIGITALHOUSE

PREGUNTAS Y RESPUESTAS

Q&A

¿Qué dudas, casos o ideas quedaron?

¡Muchas gracias!

Laura Sol Franco · Digital House

Programa de Arquitectura de Datos y Orquestación — ARCA