Siete casos, siete empresas nuevas

Cada equipo trabaja una empresa distinta, con datos sintéticos y sucios que se generan en su propio notebook. Todos son de Machine Learning. Todavía no hay notebooks: esto es la propuesta de consignas.

Equipo	Empresa	Pregunta oficial	Tipo de problema
1	Marea	¿Qué inflación mensual esperar en los próximos tres meses, y con qué margen de error?	Regresión de series de tiempo con pocos datos
2	Sembra	¿A qué solicitudes conviene aprobarles el crédito?	Clasificación desbalanceada, con costo asimétrico
3	Libretta	¿A qué clientes contactar este mes para evitar que se vayan?	Clasificación (churn) con censura y capacidad limitada
4	Tonada	¿A qué usuarios gratuitos conviene ofrecerles un descuento para que pasen a premium?	Clasificación y modelos de uplift (efecto incremental)
5	Alzo	¿A qué ascensores mandamos al técnico esta semana?	Clasificación muy desbalanceada sobre series de tiempo
6	Cobijo	¿Cuánto vale una propiedad, y con qué margen de error podemos mostrarlo?	Regresión tabular con intervalos de error
7	Vidriera	¿Qué pedidos hay que frenar o revisar antes de despachar?	Clasificación extrema con etiquetas demoradas

Mapa de modelos

Equipo	Problema de ML	Modelos que se esperan	Métrica y validación
1 · Marea	Regresión de series a 1, 2 y 3 meses	Referencia autorregresiva, Ridge y Lasso, Random Forest, XGBoost	MAE por horizonte contra la referencia; validación hacia adelante
2 · Sembra	Clasificación de la mora a 90 días	Regresión logística, árboles, Random Forest, XGBoost	Costo según el umbral, PR-AUC y calibración
3 · Libretta	Clasificación de la baja en 60 días	Regresión logística, Random Forest, XGBoost	Precisión en los 300 contactos y lift; validación temporal
4 · Tonada	Efecto incremental de un descuento	Propensión con regresión logística y XGBoost, modelos de uplift, K-means de contraste	Curva de uplift y beneficio incremental en el grupo de control
5 · Alzo	Clasificación de fallas en 14 días	Variables de ventana con XGBoost, red recurrente	Fallas capturadas en las 60 visitas; validación por tiempo
6 · Cobijo	Regresión del precio de venta	Regresión lineal regularizada, Random Forest, XGBoost	MAE, MAPE y cobertura del intervalo; validación por barrio y por tiempo
7 · Vidriera	Clasificación de fraude en pedidos	Regresión logística, Random Forest, XGBoost con pesos	PR-AUC y recall en la cola de 400 revisiones por día; validación temporal

Todos los casos incluyen, además, una red neuronal contra la mejor referencia, como en la clase 3.

CÓMO SE TRABAJARÍA

Un notebook por equipo

Abrí tu notebook

El de la empresa de tu equipo

→

Generá y limpiá

Los datos salen sucios, por código

→

Modelá y validá

Contra una referencia simple

→

Llevalo a producción

Contrato, versión y monitoreo

→

Defendé

Evidencia, límites y decisión

LOS DATOS VIENEN SUCIOS

Como en la realidad: faltantes, duplicados, valores imposibles, unidades mezcladas y categorías escritas de varias formas. Limpiar sin borrar en silencio es parte de la evidencia.

NO HAY UNA ÚNICA RESPUESTA CORRECTA

Se evalúa si la recomendación está sostenida por la evidencia, y si se declaran los límites. No se evalúa qué algoritmo se eligió.

Equipos de 3 o 4 con roles rotativos: conducción, implementación, validación y presentación.

QUÉ SE ENTREGA

Seis entregables

#	Entregable	Qué tiene	Formato
1	Notebook reproducible	Datos generados, limpieza documentada, modelos y validación; corre de punta a punta	El notebook del equipo
2	Ficha de evidencia	Decisión, población, procedimiento, resultado, validación y límite	En el notebook
3	Ficha de modelo y plan de monitoreo	Qué modelo, con qué datos, qué contrato, qué riesgos y qué señales se vigilan	Una página
4	Tablero de resultados	De 4 a 6 gráficos, uno por pregunta, con las definiciones a la vista	Superset o notebook
5	Recomendación	Evidencia, interpretación y recomendación separadas, con una limitación y un siguiente paso	Una página
6	Defensa	Decisión, evidencia, método, riesgo y siguiente paso	A definir (ver el final)

QUÉ RECORRE EL TRABAJO

Todo el programa

Módulo	Qué se evidencia
1 · Introducción	Tipo de problema, población, período, granularidad y variable objetivo
2 · Python	Limpieza documentada de datos sucios
3 · Estadística	Distribuciones, intervalos y una prueba que sostenga o contradiga una hipótesis
4 · Machine Learning	Referencia simple, al menos dos algoritmos, validación sin fuga y métricas acordes al costo del error
5 · Regresión	Cuando el objetivo es numérico, un modelo de regresión y su incertidumbre
6 · Deep Learning	Una red contra la mejor referencia: ¿cuándo mejora y cuándo solo agrega costo y opacidad?
7 · Superset	Un tablero de resultados: un gráfico por pregunta
8 · Producción	Contrato, versión, prueba de humo y plan de monitoreo
9 · Negocio	Decisión, costos, interpretabilidad y recomendación proporcional a la evidencia
10 · Proyecto final	Defensa que conecta problema, datos, modelo, validación, operación y decisión

Se considera logrado cuando...

1. Responde la pregunta y la decisión definidas
2. Declara población, período, granularidad y variable objetivo
3. Conserva una ruta reproducible desde los datos hasta la conclusión
4. Compara contra una referencia y usa métricas acordes al costo del error
5. Incluye controles de calidad, fuga, sesgo y generalización
6. Separa evidencia, interpretación y recomendación
7. Documenta al menos una limitación y un siguiente paso

ERRORES QUE HAY QUE EVITAR

- Empezar por el algoritmo.
- Ocultar resultados negativos.
- Reportar una sola métrica.
- Confundir explicación con causa.
- No declarar población, límites o responsable.

Marea

EL CASO

Marea publica todos los meses la inflación esperada para sus clientes, que ajustan precios y presupuestos con ese número. Hoy usa un promedio de los últimos meses y se equivoca cuando cambia el régimen del tipo de cambio.

LA PREGUNTA OFICIAL

¿Qué inflación mensual esperar en los próximos tres meses, y con qué margen de error?

DECISIÓN QUE HABILITA

La inflación esperada y el rango que se les publica a los clientes.

LOS DATOS (SE GENERAN EN EL NOTEBOOK)

Tabla	Filas aprox.
indicadores mensuales	~4.500
tipo de cambio diario	~5.500
publicaciones y revisiones	~9.000
calendario de publicación	~500

ANTES DE EMPEZAR

Algunos datos se publican con rezago: ¿qué sabías el día en que había que pronosticar?

Marea

Módulo	Qué tenés que resolver en tu caso
2 · Python	Pasar los datos diarios a mensuales, unificar fechas, decimales y cambios de base de los índices, y decidir qué hacer con los meses faltantes.
3 · Estadística	Estacionariedad, autocorrelación, quiebres de régimen y por qué dos series pueden parecer relacionadas sin estarlo.
4 y 5 · Modelado	Referencia autorregresiva, Ridge, Lasso, Random Forest y XGBoost; validación hacia adelante y error por horizonte.
6 · Deep Learning	Una red contra la mejor referencia, con unos 180 meses de datos: ¿se justifica?
7 · Superset	Tablero con el pronóstico, su banda de error y el error por horizonte.
8 · Producción	Contrato de entrada, versión del modelo, reentrenamiento mensual y monitoreo del error.
9 · Negocio	Cómo comunicar un número con su incertidumbre y qué escenarios mostrar; explicar sin confundir correlación con causa.

Siempre: declarar población y período, no ocultar resultados negativos y cerrar con una recomendación proporcional a la evidencia.

Sembra

EL CASO

Sembra otorga microcréditos a personas con ingresos informales. Hoy aprueba con reglas manuales y quiere una política basada en datos que apruebe a más personas sin aumentar la mora.

LA PREGUNTA OFICIAL

¿A qué solicitudes conviene aprobarles el crédito?

DECISIÓN QUE HABILITA

La política de aprobación: el puntaje de corte y el monto máximo.

LOS DATOS (SE GENERAN EN EL NOTEBOOK)

Tabla	Filas aprox.
solicitantes	~14.000
solicitudes	~16.000
cuotas y pagos	~110.000
consultas al buró	~13.000

ANTES DE EMPEZAR

No todas las solicitudes tienen resultado: solo se conoce la mora de quienes recibieron el crédito.

Sembra

Módulo	Qué tenés que resolver en tu caso
2 · Python	Llevar los ingresos a una sola unidad y moneda, unificar fechas, resolver solicitantes duplicados y documentar cada decisión.
3 · Estadística	Distribución de los ingresos y tasa de mora por segmento, con su intervalo de confianza.
4 y 5 · Modelado	Regresión logística, árboles, Random Forest y XGBoost; umbral y métricas según el costo de cada tipo de error.
6 · Deep Learning	Una red neuronal tabular contra la mejor referencia: ¿mejora lo bastante para justificar su costo y su opacidad?
7 · Superset	Un tablero con la mora por segmento, la tasa de aprobación y el efecto del umbral.
8 · Producción	Contrato de entrada del servicio de scoring, versión del modelo y plan de monitoreo.
9 · Negocio	La política de aprobación, el costo de equivocarse y una explicación global y una local, sin presentarlas como causalidad.

Siempre: declarar población y período, no ocultar resultados negativos y cerrar con una recomendación proporcional a la evidencia.

Libretta

EL CASO

Libretta vende suscripciones mensuales de un software de facturación a pymes. Cada baja es un cliente que tardó meses en convertirse, y el equipo de éxito solo puede contactar a una parte.

LA PREGUNTA OFICIAL

¿A qué clientes contactar este mes para evitar que se vayan?

DECISIÓN QUE HABILITA

La lista mensual de clientes a contactar, con capacidad para 300.

LOS DATOS (SE GENERAN EN EL NOTEBOOK)

Tabla	Filas aprox.
cuentas	~11.000
suscripciones y pagos	~95.000
eventos de uso	~400.000
tickets de soporte	~20.000

ANTES DE EMPEZAR

Hay clientes que recién empezaron: no tuvieron tiempo de irse, y eso no significa que no se vayan a ir.

Libretta

Módulo	Qué tenés que resolver en tu caso
2 · Python	Unificar planes con nombres distintos, resolver cuentas y eventos duplicados, y distinguir pausas, pagos fallidos y bajas.
3 · Estadística	Tasa de baja por antigüedad y por plan, con intervalos, y qué cambia si se cuentan o no los clientes recientes.
4 y 5 · Modelado	Variables de uso por ventana; regresión logística, Random Forest y XGBoost; validación temporal; precisión en los 300 contactos.
6 · Deep Learning	Una red tabular contra el mejor modelo de árboles: ¿cuándo mejora y cuándo solo agrega costo?
7 · Superset	Tablero con riesgo por segmento, clientes a contactar y bajas evitadas.
8 · Producción	Contrato de entrada, versión y monitoreo de la deriva del uso, que cambia con los cierres fiscales.
9 · Negocio	El costo de contactar frente al de perder al cliente, y qué decir en cada contacto; explicación sin causalidad.

Siempre: declarar población y período, no ocultar resultados negativos y cerrar con una recomendación proporcional a la evidencia.

Tonada

EL CASO

Tonada ofrece descuentos para que sus usuarios gratuitos pasen a premium, pero algunos habrían pagado igual sin descuento. Cada descuento innecesario es ingreso que se pierde.

LA PREGUNTA OFICIAL

¿A qué usuarios gratuitos conviene ofrecerles un descuento para que pasen a premium?

DECISIÓN QUE HABILITA

A quién se le ofrece el descuento y de qué porcentaje: 10 %, 20 % o 30 %.

LOS DATOS (SE GENERAN EN EL NOTEBOOK)

Tabla	Filas aprox.
usuarios	~20.000
reproducciones	~400.000
ofertas anteriores con resultado	~15.000
catálogo	~5.000

ANTES DE EMPEZAR

Quien acepta un descuento no es lo mismo que quien solo paga con descuento: ¿cómo separás a los que habrían pagado igual?

Tonada

Módulo	Qué tenés que resolver en tu caso
2 · Python	Quitar reproducciones duplicadas y saltos de menos de 5 segundos, detectar bots y cuentas compartidas, y unificar géneros.
3 · Estadística	Conversión con y sin descuento, su diferencia con intervalo y una prueba de hipótesis sobre el efecto.
4 y 5 · Modelado	Propensión con regresión logística y XGBoost, modelos de uplift con los vistos y K-means de contraste; evaluación en el grupo de control.
6 · Deep Learning	Una red contra los modelos de árboles: ¿mejora el uplift o solo la propensión?
7 · Superset	Tablero con uplift por decil, costo de los descuentos e ingreso incremental.
8 · Producción	Contrato de entrada, versión y por qué hay que conservar siempre un grupo de control.
9 · Negocio	La política de descuentos según margen: a quién ofrecer, de cuánto y a quién no ofrecer nada.

Siempre: declarar población y período, no ocultar resultados negativos y cerrar con una recomendación proporcional a la evidencia.

Alzo

EL CASO

Alzo mantiene unos 900 ascensores en edificios. Los técnicos visitan cada equipo por calendario fijo, pero algunas fallas ocurren entre una visita y otra.

LA PREGUNTA OFICIAL

¿A qué ascensores mandamos al técnico esta semana?

DECISIÓN QUE HABILITA

La lista semanal de visitas, con capacidad para 60 equipos.

LOS DATOS (SE GENERAN EN EL NOTEBOOK)

Tabla	Filas aprox.
equipos	~900
lecturas de sensores	~250.000
órdenes de servicio	~12.000
fallas registradas	~2.500

ANTES DE EMPEZAR

Las órdenes de servicio se cargan después de la falla: mirá qué sabías en cada momento.

Alzo

Módulo	Qué tenés que resolver en tu caso
2 · Python	Unificar los identificadores de equipo, las unidades de temperatura y las marcas de tiempo; decidir qué hacer con los días sin lectura.
3 · Estadística	Distribución de las lecturas por equipo, valores atípicos y tasa de fallas en una ventana de 14 días.
4 y 5 · Modelado	Variables de ventana, regresión logística, Random Forest y XGBoost; validación por tiempo y fallas capturadas en las 60 visitas.
6 · Deep Learning	Una red recurrente sobre las ventanas de sensores contra las variables agregadas: ¿vale la pena?
7 · Superset	Tablero con los equipos priorizados, las fallas capturadas y el estado de los sensores.
8 · Producción	Contrato de entrada del servicio, prueba de humo con equipos de borde y señales de deriva de los sensores.
9 · Negocio	El costo de una visita en vano frente al de una falla; explicación de por qué un equipo quedó en la lista.

Siempre: declarar población y período, no ocultar resultados negativos y cerrar con una recomendación proporcional a la evidencia.

Cobijo

EL CASO

Cobijo publica avisos de propiedades y quiere ofrecer una tasación automática a quienes van a vender, para captar más publicaciones.

LA PREGUNTA OFICIAL

¿Cuánto vale una propiedad, y con qué margen de error podemos mostrarlo?

DECISIÓN QUE HABILITA

El precio sugerido, el rango que se muestra y a qué propiedades no se les da tasación automática.

LOS DATOS (SE GENERAN EN EL NOTEBOOK)

Tabla	Filas aprox.
avisos	~35.000
historial de precios	~60.000
operaciones cerradas	~6.000
barrios	~120

ANTES DE EMPEZAR

El precio publicado no es el precio al que se vende: ¿qué estás prediciendo exactamente?

Cobijo

Módulo	Qué tenés que resolver en tu caso
2 · Python	Pasar las superficies escritas como texto a números, unificar USD y pesos y las grafías de los barrios, y quitar avisos republicados y precios con un cero de más.
3 · Estadística	Distribución del precio (asimétrica) y su logaritmo; relación con superficie y barrio, con intervalos.
4 y 5 · Modelado	Regresión lineal regularizada, Random Forest y XGBoost sobre el logaritmo del precio; validación dejando barrios o períodos afuera.
6 · Deep Learning	Una red tabular con representación del barrio contra el boosting: ¿mejora lo bastante?
7 · Superset	Tablero con el error por barrio y por tipo de propiedad.
8 · Producción	Contrato de entrada, versión y monitoreo del error cuando cambia el mercado.
9 · Negocio	Cuándo no dar tasación por baja confianza, y cómo explicarle el precio a quien vende, sin discriminar.

Siempre: declarar población y período, no ocultar resultados negativos y cerrar con una recomendación proporcional a la evidencia.

Vidriera

EL CASO

Vidriera paga cada contracargo de tarjeta que le reclaman. Revisa pedidos a mano antes de despachar, pero solo alcanza a mirar una fracción.

LA PREGUNTA OFICIAL

¿Qué pedidos hay que frenar o revisar antes de despachar?

DECISIÓN QUE HABILITA

Cuáles se bloquean, cuáles se revisan a mano (con capacidad para 400 por día) y cuáles se aprueban.

LOS DATOS (SE GENERAN EN EL NOTEBOOK)

Tabla	Filas aprox.
pedidos	~150.000
pagos y contracargos	~150.000
clientes	~40.000
dispositivos	~60.000

ANTES DE EMPEZAR

El contracargo llega semanas después: los pedidos más recientes todavía no tienen su etiqueta.

Vidriera

Módulo	Qué tenés que resolver en tu caso
2 · Python	Resolver pedidos duplicados por reintentos, direcciones y correos con variantes, importes con coma y con punto, y fechas en distintas zonas horarias.
3 · Estadística	Tasa de fraude de alrededor del 0,8 % con su intervalo, y diferencias entre grupos de pedidos.
4 y 5 · Modelado	Regresión logística, Random Forest y XGBoost con pesos; validación temporal con una ventana de maduración; PR-AUC y recall en la cola de 400.
6 · Deep Learning	Una red contra XGBoost con menos del 1 % de casos positivos: ¿se justifica?
7 · Superset	Tablero con la cola de revisión, el fraude capturado y la fricción a clientes buenos.
8 · Producción	Contrato de entrada, tiempo de respuesta en milisegundos, dos umbrales y deriva, porque quienes defraudan se adaptan.
9 · Negocio	El costo de un contracargo frente al de frenar a un cliente bueno; explicación para el analista que revisa.

Siempre: declarar población y período, no ocultar resultados negativos y cerrar con una recomendación proporcional a la evidencia.

Lo que se escondeŕía en los datos

Es lo planeado: se verifica al generar los datos, y recién ahí se pasa a la referencia del facilitador con números.

Equipo	Suciedad planeada	Trampa de modelado	Hipótesis de lo que debería concluir un buen equipo
1 · Marea	Series diarias y mensuales mezcladas, fechas en dos formatos, decimales con coma, cambios de base de los índices, meses faltantes, valores revisados que reemplazan a los publicados y un salto del tipo de cambio.	Fuga por usar datos que todavía no se habían publicado, y correlaciones entre series que no significan nada.	Una referencia simple es difícil de superar; con unos 180 meses los modelos con muchas series se sobreajustan; probablemente gane un modelo regularizado y simple, con un rango de error honesto.
2 · Sembra	Ingresos escritos como texto y en dos monedas, fechas en dos formatos, personas duplicadas, edades imposibles, una variable que solo se conoce después del atraso, rechazados sin resultado y mora de alrededor del 8 %.	Sesgo de selección y fuga por una variable posterior al otorgamiento.	La política no se puede evaluar solo con quienes recibieron el crédito: hay que declarar ese sesgo, elegir el umbral con costos y no usar la variable posterior.
3 · Libretta	Planes escritos de varias maneras, cuentas duplicadas por dos altas, eventos duplicados por reintentos, fechas en dos formatos, pausas que parecen bajas, pagos fallidos reintentados, una fecha de baja que se conoce después y bajas de alrededor del 4 % mensual.	Censura de los clientes recientes y fuga por la fecha de solicitud de baja.	Hay que definir qué es una baja y la ventana antes de modelar, validar por tiempo y medir el valor en los 300 contactos, no el AUC.
4 · Tonada	Reproducciones duplicadas, saltos contados como escucha, cuentas compartidas, bots que escuchan 24 horas, géneros con variantes, fechas en distintas zonas horarias y ofertas anteriores dirigidas sin azar, salvo un grupo de control del 10 %.	Optimizar la conversión premia a quienes habrían pagado igual; las ofertas previas no fueron al azar.	La decisión depende del efecto incremental, que solo se puede evaluar bien en el grupo de control aleatorio; ofrecer a quien más probablemente compre no es lo mismo que ofrecer a quien más cambia por el descuento.

Lo que se esconder[ía en los datos

Equipo	Suciedad planeada	Trampa de modelado	Hipótesis de lo que debería concluir un buen equipo
5 · Alzo	Lecturas faltantes por cortes de luz, temperaturas en °C y en °F, marcas de tiempo duplicadas, vibraciones con error de calibración, identificadores en varios formatos y fallas de entre el 1 % y el 2 %.	Fuga temporal y partición aleatoria de datos que son series de tiempo.	Hay que validar por tiempo, no al azar, y medir cuántas fallas se capturan con 60 visitas; la red solo se justifica si mejora ese número.
6 · Cobijo	Superficies escritas como texto, precios en dólares y en pesos mezclados, barrios con grafías distintas, avisos duplicados o republicados, ambientes imposibles y precios con un cero de más.	El precio publicado no es el de cierre, y los vecinos en entrenamiento y prueba inflan el resultado.	Conviene entrenar con operaciones cerradas o declarar el sesgo, validar dejando barrios afuera y mirar el error por segmento, no solo el promedio.
7 · Vidriera	Pedidos duplicados por reintentos, direcciones y correos con variantes, importes con coma y con punto, fechas en distintas zonas horarias, países con varios nombres y etiquetas que llegan con semanas de demora.	Etiquetas demoradas y partición aleatoria: parece que anda perfecto y no anda.	Hay que excluir o madurar las últimas semanas, validar por tiempo, medir en la cola de 400 pedidos y fijar dos umbrales, uno para bloquear y otro para revisar.

Lo que necesito que me confirmes

#	Tema	Qué decidir
1	Los casos extra	Te propongo tres y no dos: con los cuatro que pediste más dos extra son seis equipos, y siempre trabajamos con siete. Los extra son Alzo, Cobijo y Vidriera. Si preferís otro, hay reservas: demanda de perecederos, plazo de reparación de un taller y tickets de soporte.
2	El caso macro	Sería un país ficticio, con datos que se parecen a una economía con cambios de régimen pero sin referencias a datos oficiales reales. ¿Está bien así?
3	El uplift	El caso de Tonada pide medir el efecto incremental de un descuento. Excede el temario de Machine Learning, pero se resuelve con modelos que ya vieron. ¿Lo dejamos o lo simplificamos a propensión?
4	Deep Learning	Propongo que todos comparen una red con la mejor referencia, como en la clase 3. ¿Obligatorio en todos o solo donde se justifica?
5	Defensa y datos	La guía prevé 4 minutos más 3 de preguntas: con siete equipos hay que armar paneles o dar más tiempo. Y los datos llegan a unas 400.000 filas por caso, para que cada notebook corra en pocos minutos. ¿Está bien?