DIGITALHOUSE CLASE EN VIVO 2

ARCA | AGENCIA DE RECAUDACIÓN Y CONTROL ADUANERO

Machine Learning aplicado

Clase en vivo 2 · 120 minutos

Programa Profesional: Científico de Datos (Data Scientist) — ARCA

Escaneá el QR para registrar tu asistencia

Me presento...

1. Directora General en The eLabs: transformación digital e integración de IA.
2. Host del podcast Hack The Future: estrategia y liderazgo, no solo algoritmos.
3. Docente en la Maestría en Ciencia de Datos (Univ. Austral), ITBA y Di Tella.



Apasionada por aplicar IA para mejorar la productividad y las decisiones.

Lo que dejó la clase 1

1 Un cliente por fila

Quitamos las filas repetidas: 8.000 clientes únicos.

2 Controlar antes de afirmar

Faltantes, valores imposibles y población, antes de concluir.

3 Fuera lo que llega tarde

motivo_baja solo existe después de abandonar: es fuga.

Hoy aplicamos los módulos 3 y 4: clasificación, métricas y evaluación de modelos.

Qué vamos a lograr hoy

PROPÓSITO

Comparar modelos de clasificación y elegir umbral y métrica según el costo del error.

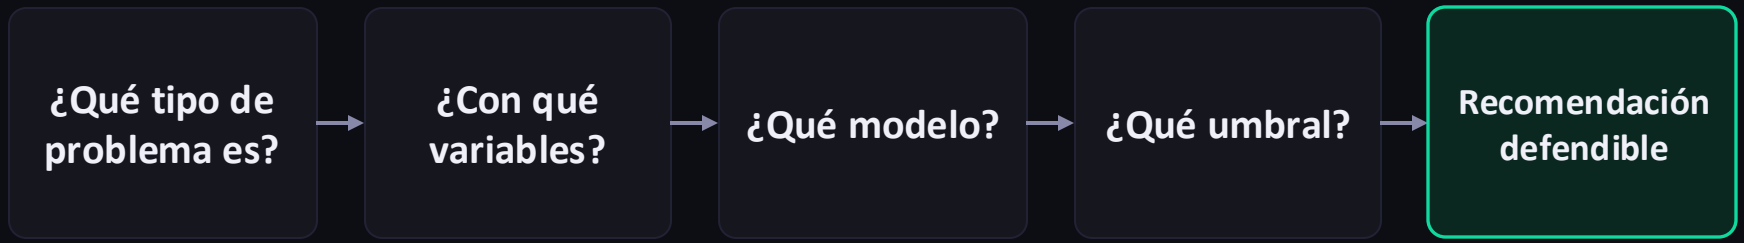
RESULTADO OBSERVABLE

Tabla comparativa, umbral elegido, matriz de confusión, validación de fuga y recomendación.

Dos actividades en equipo: una práctica guiada y un desafío. Son siete equipos y siete casos distintos en cada una.

La pregunta de la clase

¿Qué modelo y qué umbral debería usar NovaRetail para priorizar contactos sin saturar al equipo comercial?



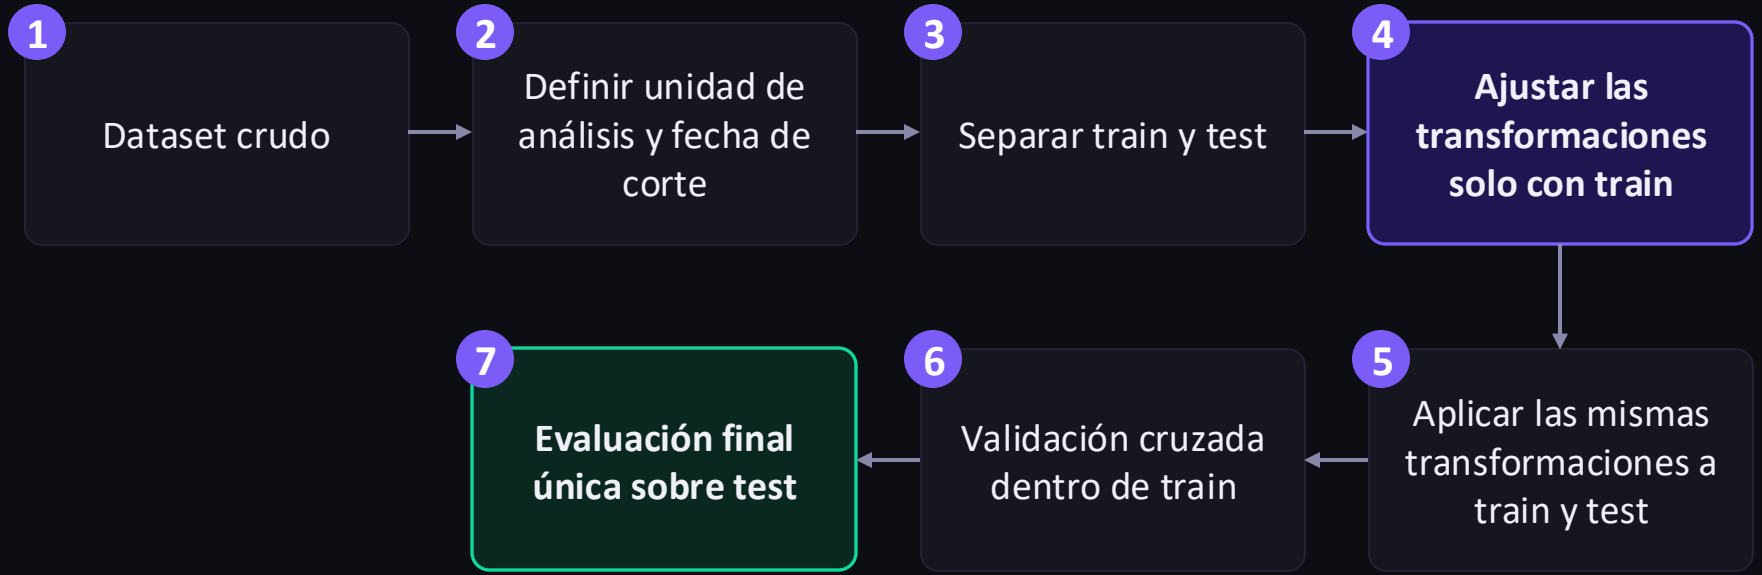
Dónde estamos y qué problema es

8.000	14 %	300	5 y 60
clientes únicos	tasa de abandono	contactos por cada 2.000 clientes	costo de contactar y de perder

Clasificación binaria sobre abandono_90d: no es regresión ni clustering.

Datos sintéticos: ningún resultado representa una situación real de ARCA.

El proceso, de punta a punta



Todo se ajusta con train; el test se usa una sola vez.

Cómo sabemos si un modelo sirve

1

Entrenamiento y prueba

Se aprende con una parte y se mide con otra que no se vio.

2

Validación cruzada

Rotar la parte de validación dentro del entrenamiento.

3

Línea base

Un modelo simple contra el cual comparar.

4

Generalización

Que funcione con datos nuevos, no solo con los vistos.

5

Semilla

Repite el sorteo: comparaciones justas.

¿Cómo definimos el mejor modelo? Con las mismas filas y el mismo criterio para todos.

Separar antes de tocar nada



Las dos partes tienen la misma tasa de abandono: la comparación es justa.

Datos que el modelo pueda usar

1 Imputar faltantes

Mediana para números, la más frecuente para categorías.

2 Codificar categorías

Canal, segmento y región pasan a columnas de 0 y 1.

3 Escalar

Todas las variables en una escala comparable.

4 Crear variables nuevas

Valores pasados, medias móviles y calendario.

Los modelos no entienden fechas ni categorías: hay que convertirlas en números.

Solo lo que existe al decidir

ENTRAN (13)

Numéricas: edad, antigüedad, compras, ticket, días sin comprar, contactos a soporte, uso de la app, descuento, satisfacción

Categóricas: canal, segmento, región

Indicador: satisfacción faltante

NO ENTRAN

motivo_baja: solo existe después de abandonar. Es fuga.

id_cliente: identifica, no describe.

fecha_alta: ya está en la antigüedad.

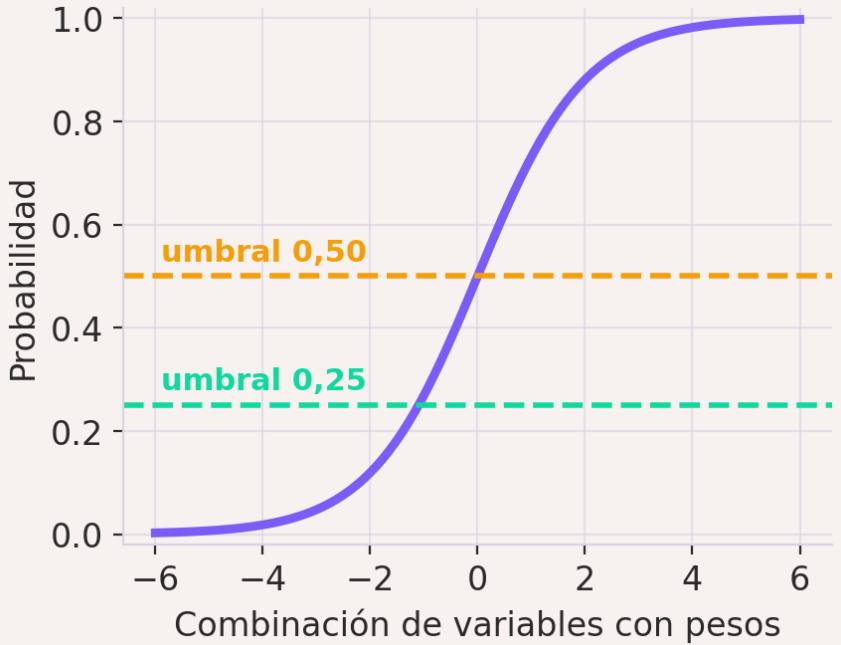
Regla: solo variables disponibles en el momento de decidir.

De la regresión lineal a una probabilidad

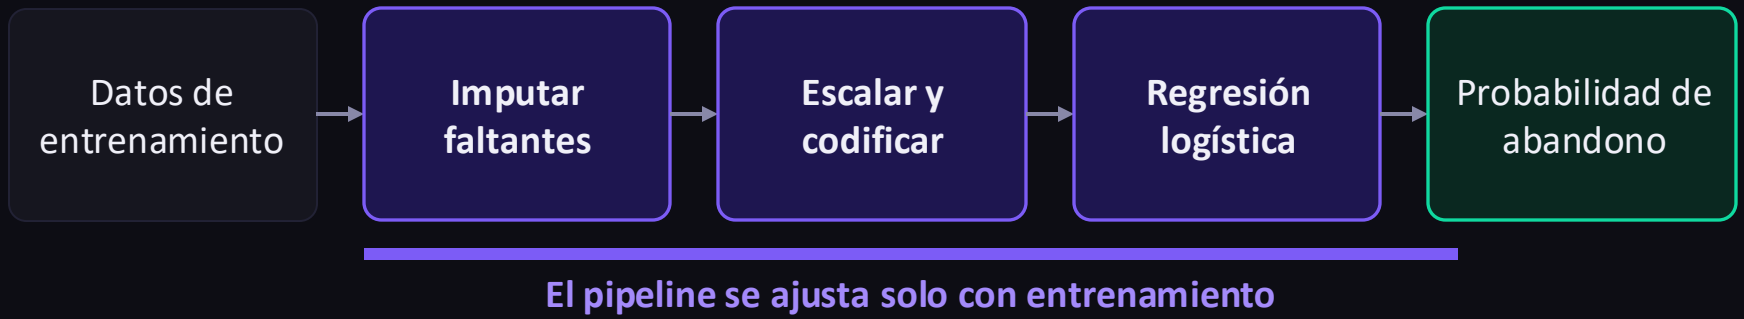
Combina las variables con pesos y lleva el resultado a una probabilidad entre 0 y 1.

$$p = 1 / (1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots)})$$

- Se explica con coeficientes.
- Rápida: buena línea base.
- Sensible a outliers y multicolinealidad.



Un solo objeto, sin filtrar nada





Cinco formas de medir un acierto

KPI	Qué mide	Fórmula
Accuracy	Porcentaje de predicciones correctas	(VP + VN) / total
Precisión	De los que marcamos, cuántos se iban de verdad	VP / (VP + FP)
Recall (sensibilidad)	De los que se iban, cuántos encontramos	VP / (VP + FN)
F1	Promedio armónico de precisión y recall	2 · P · R / (P + R)
AUC	Qué tan bien ordena, sin elegir umbral	Área bajo la curva ROC

VP verdadero positivo · VN verdadero negativo · FP falso positivo · FN falso negativo

Acertar casi siempre es fácil

Modelo	Accuracy	Bajas encontradas
Siempre dice "no abandona"	85,7 %	0 de 286
Regresión logística (umbral 0,5)	87,8 %	77 de 286

Dos puntos más de accuracy, y solo 27 de cada 100 bajas encontradas.

MATRIZ DE CONFUSIÓN

Lo que predijo, lo que pasó

	Predijo: sigue	Predijo: abandona	
Real: sigue	**VN** 1.678	**FP** 36	**Precisión** 68,1 % (77 de 113)
Real: abandonó	**FN** 209	**VP** 77	**Recall** 26,9 % (77 de 286)

Marca pocos clientes y son confiables, pero se le escapan casi tres de cada cuatro bajas.

Bajar el umbral cambia la decisión

Con costos de 5 y 60	Umbral 0,50	Umbral 0,25
Clientes contactados	113	363
Precisión	68,1 %	45,7 %
Recall	26,9 %	58,0 %
F1	0,386	0,512
Costo total	12.720	8.185

El costo baja 36 % al bajar el umbral: elegirlo depende de cuánto cuesta cada error.

PRÁCTICA GUIADA

Dos umbrales, tu caso

1 Tu caso

Cambiá MI_CASO por el número de tu equipo.

2 Dos umbrales

Calculá precisión, recall y F1 en los dos.

3 Tu decisión

Elegí uno y justificalo con el costo de cada error.

LOS SIETE CASOS

1	2	3	4	5	6	7
Cupón web	Premium	Primer año	Inactivos	Puntos extra	Mail masivo	Descuento fuerte

La capacidad manda

Umbral de menor costo (0,06)

1.132 clientes contactados

Capacidad del equipo (umbral cercano a 0,28)

300

Bajas encontradas: 267 · Costo: 5.465

Bajas encontradas: 153 · Costo: 8.715

La capacidad, no el costo, define el umbral.

PAUSA

Antes de seguir

1 Una decisión confirmada

Algo que tu equipo ya puede defender.

2 Una duda

Lo que todavía no cierra.

3 Un riesgo

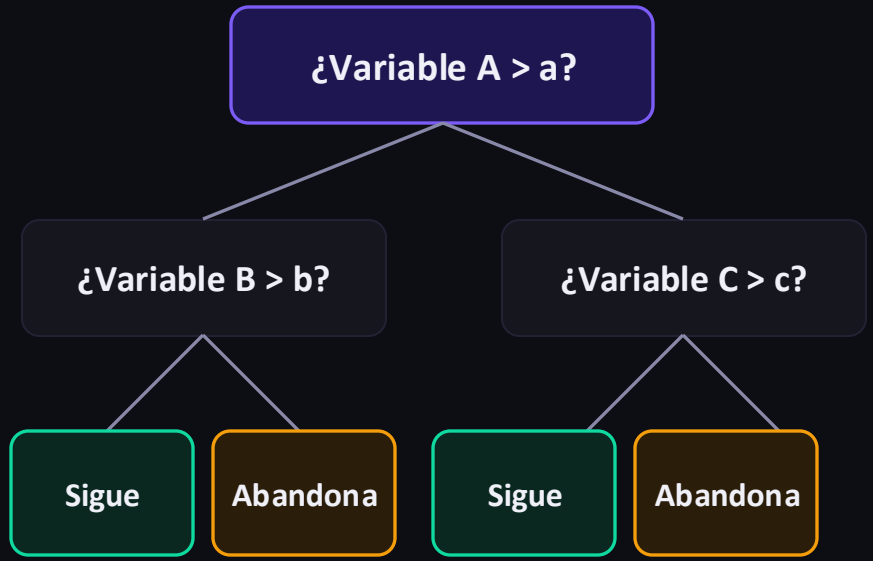
Lo que podría cambiar la conclusión.

Dejá escrita una pregunta pendiente: el desafío arranca con las dudas de todos.

Reglas hasta llegar a una predicción

Segmenta los datos con reglas de decisión hasta llegar a una predicción.

- Intuitivo y visualmente explicable.
- Numéricas y categóricas.
- Sobreajusta si no se controla la profundidad.
- Sensible a pequeños cambios en los datos.



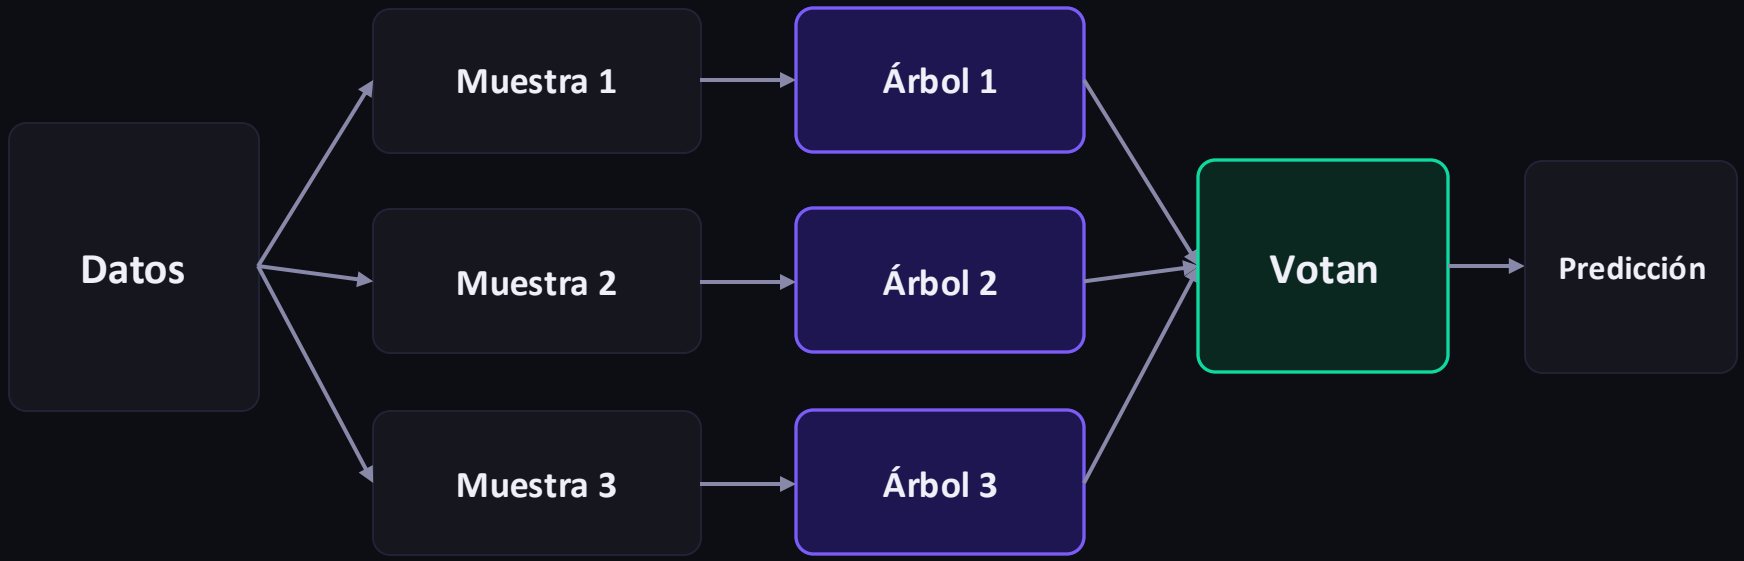
Ejemplo ilustrativo: cada hoja devuelve una clase y la proporción de cada clase.

Combinar modelos para mejorar

Combinar varios modelos produce uno más preciso, robusto y generalizable que cualquiera por separado.

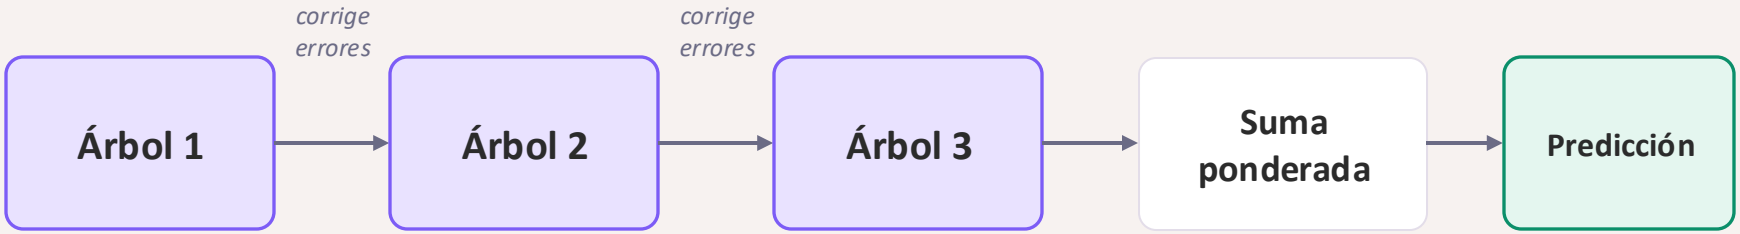
Método	Idea	Cómo funciona	Ejemplo	Ventaja
Bagging	Reducir varianza	Entrena en paralelo sobre muestras aleatorias	Random Forest	Menos sobreajuste
Boosting	Reducir sesgo	Entrena en secuencia: cada uno corrige al anterior	XGBoost	Alta precisión
Stacking	Combinar modelos	Un meta-modelo aprende a combinar las predicciones	Modelos apilados	Máxima flexibilidad

Muchos árboles que votan



Menos sobreajuste que un árbol y robusto al ruido; a cambio, menos interpretable.

Árboles que corrigen errores

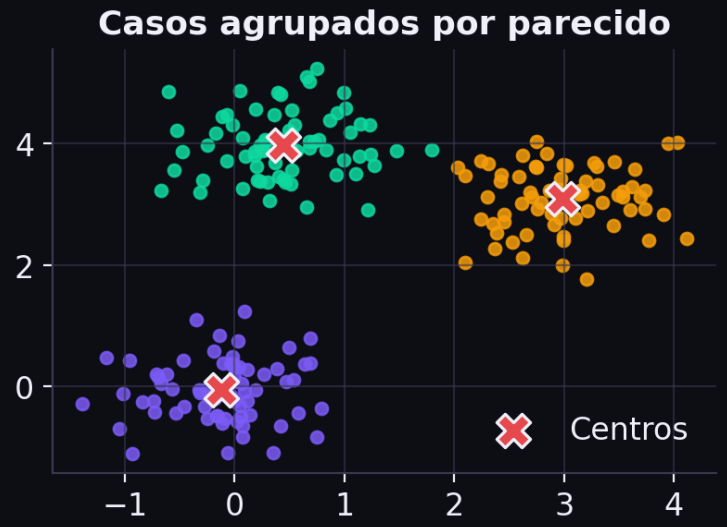


Random Forest
en paralelo: los árboles votan

XGBoost
en secuencia: cada árbol corrige al anterior

Alta precisión y regularización; pide un ajuste cuidadoso de hiperparámetros.

Agrupar sin variable objetivo





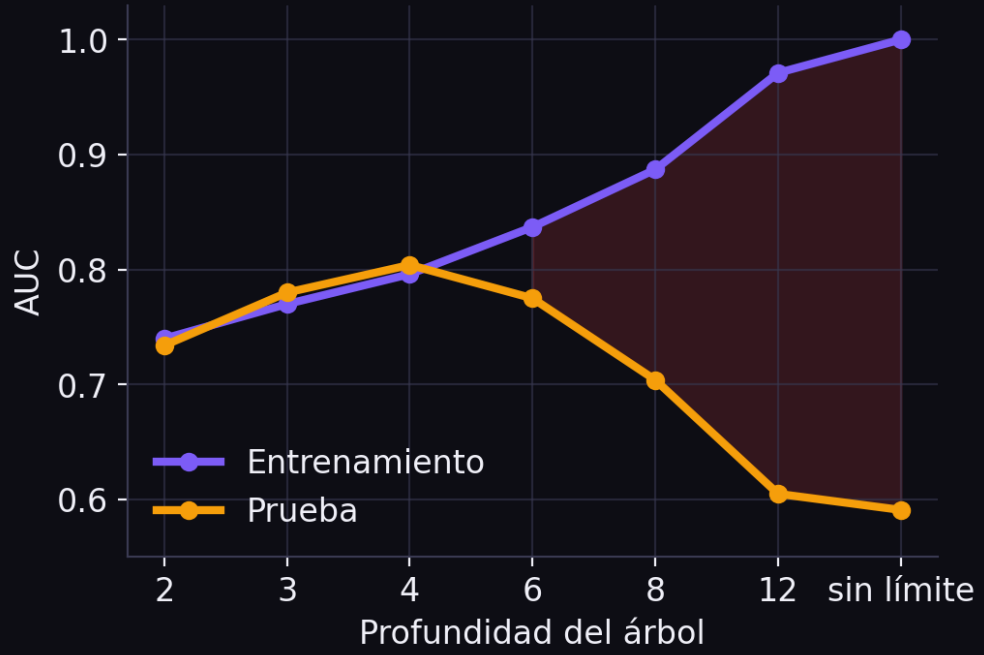
No predice: describe y segmenta. K se elige con el método del codo.

Comparar con las mismas filas

Modelo	AUC validación cruzada	AUC prueba	Se explica con
Regresión logística	0,83	0,84	coeficientes
Árbol (profundidad 4)	0,78	0,80	reglas
Random Forest	0,82	0,82	importancias
XGBoost (opcional)	0,82	0,83	importancias

Ningún ensamble le gana a la regresión logística. Diferencias de 0,02 no son concluyentes.

Cuando el árbol memoriza

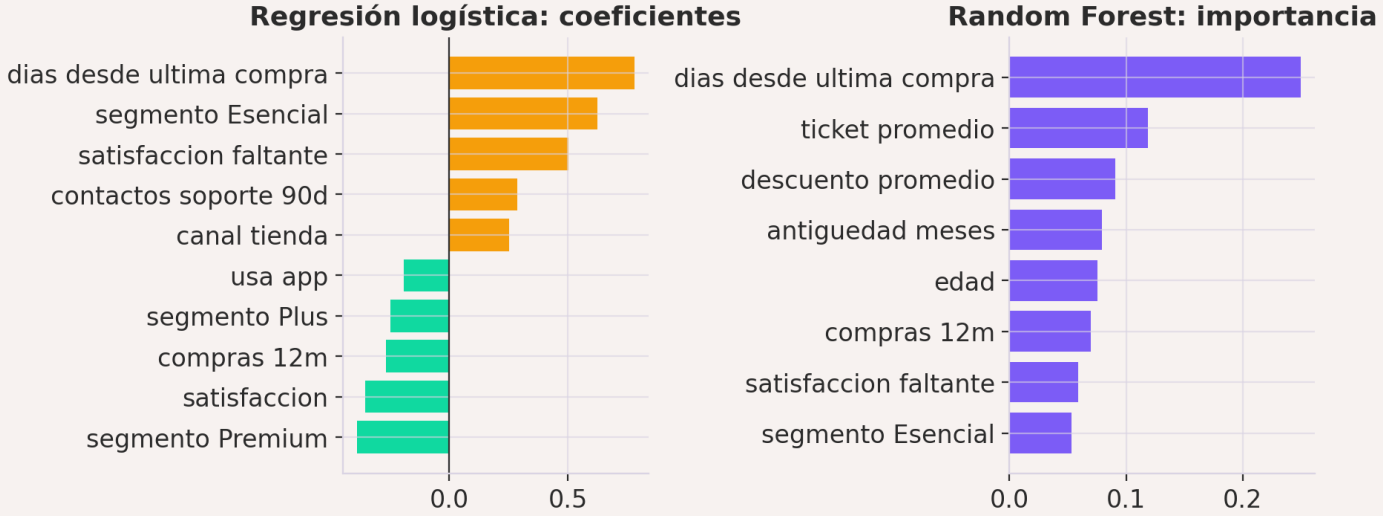


Hasta profundidad 4, las dos curvas suben juntas.

Profundidad 12: 0,97 en entrenamiento y 0,60 en prueba.

La profundidad se elige con validación, nunca con la prueba.

Qué pesa, no qué causa



Importancia no es causalidad: una alta correlación tampoco implica una relación causal.

Calibración y fuga

CALIBRACIÓN



FUGA

Sin motivo_baja: AUC 0,84

Con motivo_baja: AUC 1,00

Un resultado perfecto es una alarma, no un logro.

Se usa la probabilidad si está calibrada; se sospecha de lo que parece perfecto.

Cinco errores que cambian la conclusión

Error	Qué pasa	Cómo se evita
Optimizar sobre la prueba	El costo prometido es 5 % optimista	Elegir con validación; mirar la prueba una vez
Particiones distintas	El AUC se mueve 0,025 solo por la partición	El mismo split para todos
Accuracy como única métrica	Baja con el umbral 0,25, pero el costo cae 36 %	Precisión, recall y costo
Importancia como causalidad	"Pesa" no es "causa"	Decir qué pesa, no qué causa
Ignorar la calibración	Ordena bien, pero la probabilidad está inflada	Revisar la curva de calibración

Cómo se trabaja

Conducción

Ordena el trabajo y la discusión.

Implementación

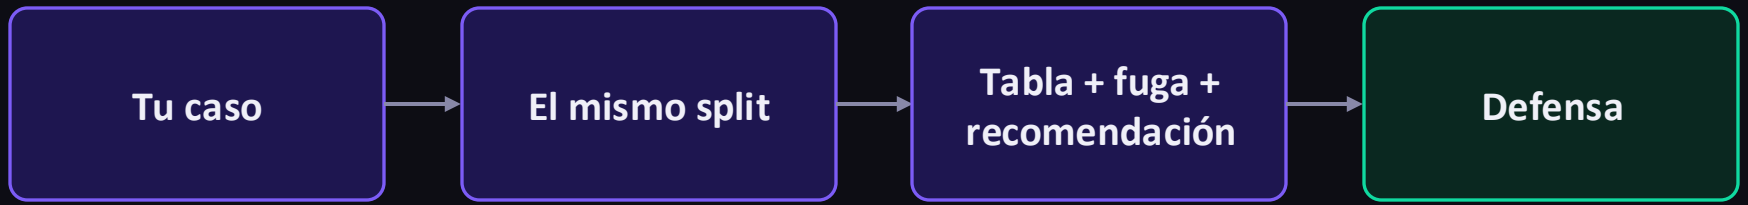
Escribe y corre el código.

Validación

Controla fuga, partición y tamaño.

Presentación

Cuenta la decisión y el límite.



Los roles rotan. Todos usan los mismos datos y el mismo split.

Siete casos, siete complicaciones

1

Capacidad limitada

El umbral de menor costo pide más llamadas de las que hay.

2

Contactar se vuelve caro

Contactar cuesta 20: cambia el umbral que conviene.

3

No todos valen lo mismo

Perder cuesta 30, 60 o 120 según el segmento.

4

Canales

Una métrica global puede esconder un canal desatendido.

5

El árbol que memoriza

Más profundo: mejor en entrenamiento, peor en prueba.

6

¿Vale el ensamble?

Ganancia chica, más costo y más opacidad.

7

¿Confiar en la probabilidad?

Una variable posterior infla la métrica.

Cinco preguntas, en este orden

1. ¿Qué decisión habilita?
2. ¿Cuál es la población y el período?
3. ¿Cómo evitaron fuga o sesgo?
4. ¿Qué validaron?
5. ¿Qué no pueden afirmar?

No se resuelve la tarea: se devuelve el criterio para elegir el siguiente paso.

Siete criterios de calidad

1. Responde la pregunta y la decisión
2. Declara población, período, granularidad y objetivo
3. Ruta reproducible, de los datos a la conclusión
4. Compara con una referencia y usa métricas según el costo
5. Controles de calidad, fuga, sesgo y generalización
6. Separa evidencia, interpretación y recomendación
7. Documenta una limitación y un siguiente paso

Presentar, preguntar y devolver

El equipo presenta

La decisión, la tabla y el límite.

El equipo revisor pregunta

Una técnica, una de negocio y una de riesgo.

Devolución en vivo

Una fortaleza, una brecha prioritaria y una mejora verificable.

Una devolución sin un próximo paso verificable no está terminada.

Qué me llevo y qué dejo escrito

CUATRO IDEAS PARA LLEVARSE

1. **Qué se predice y con qué**
   Solo variables disponibles al decidir.
2. **El accuracy engaña**
   Mirá precisión, recall y costo.
3. **El umbral lo define el negocio**
   Costo de cada error y capacidad.
4. **Lo perfecto es una alarma**
   Y la probabilidad se usa si está calibrada.

TICKET DE SALIDA · UNA FRASE POR CADA UNO

Qué repetiría

Lo que mejor funcionó.

Qué verificaría

Lo que todavía no está controlado.

Qué no llevaría a producción

Lo que todavía no está listo.

LO QUE VIENE

Hacia la clase 3

La regresión logística quedó como línea base

→

¿Cuándo una red neuronal mejora esta solución?

Costo

Opacidad

Eso introduce la clase 3: Deep Learning y modelos avanzados.

DIGITALHOUSE

ARCA | AGENCIA DE RECAUDACIÓN Y CONTROL ADUANERO

PREGUNTAS Y RESPUESTAS

Q&A

¿Qué dudas, casos o ideas quedaron?

¡Muchas gracias!



Agradecemos que respondas esta encuesta

Laura Sol Franco · Digital House

Programa Profesional: Científico de Datos (Data Scientist) — ARCA