DIGITALHOUSE CLASE EN VIVO 3

ARCA | AGENCIA DE RECAUDACIÓN Y CONTROL ADUANERO

Deep Learning y modelos avanzados

Clase en vivo 3 · 120 minutos

Programa Profesional: Científico de Datos (Data Scientist) — ARCA



Escaneá el QR para registrar tu asistencia

Me presento...

1. Directora General en The eLabs: transformación digital e integración de IA.
2. Host del podcast Hack The Future: estrategia y liderazgo, no solo algoritmos.
3. Docente en la Maestría en Ciencia de Datos (Univ. Austral), ITBA y Di Tella.



Apasionada por aplicar IA para mejorar la productividad y las decisiones.

REPASO

Lo que traés del curso

1 De Regresión: la línea base

Una regresión regularizada es el punto de partida contra el que se compara todo.

2 De Fundamentos: entrenar sin sobreajustar

Pérdida, gradiente y detención temprana.

3 De Implementación: la red como comparación

Una red se prueba contra algo más simple; no se da por buena.

Módulo de Deep Learning: Intro · Fundamentos · Redes convolucionales · Recurrentes · Transformers · Generativos · Implementación · Aplicaciones

¿Qué decisión tomaron distinto después de ver las clases online?

Qué vamos a lograr hoy

PROPÓSITO

Elegir una arquitectura proporcional al problema y evaluar si Deep Learning aporta valor frente a una línea base.

RESULTADO OBSERVABLE

Un canvas de experimento: arquitectura justificada, línea base, métrica, validación, riesgos y condición de abandono.

Dos actividades en equipo: una práctica guiada y un desafío. Son siete equipos y siete casos distintos en cada una.

La pregunta de la clase

¿Cuándo una red neuronal mejora una solución y cuándo solo agrega costo y opacidad?

Una línea base Primero lo simple	**Costo** Entrenar y operar	**Opacidad** Explicar cada decisión	**Riesgo** Sesgo y errores

La respuesta depende de los datos: hoy la medimos en dos casos.

NovaRetail: dónde estamos

8.000 clientes

14,3 % abandona en 90 días.

Línea base

Regresión logística: AUC 0,837.

Caso 2

La misma tabla, con otra regla de abandono.

Hoy comparamos los dos casos con el mismo método: misma partición y misma métrica.

Machine Learning y Deep Learning

	Machine Learning clásico	Deep Learning
Variables	Se arman a mano	La red aprende sus propias representaciones
Datos	Funciona con pocos	Suele necesitar muchos más
Cómputo	Segundos en una computadora común	Puede pedir mucho más tiempo y hardware
Explicar	Coeficientes e importancias	Opaco: cuesta explicar cada decisión
Mejor terreno	Datos en tabla	Imagen, secuencia y texto

En esta clase lo medimos, no lo suponemos.

Anatomía de una red

Entradas
Las variables del cliente

→

Capas ocultas
Neuronas que combinan

→

Salida
Una probabilidad

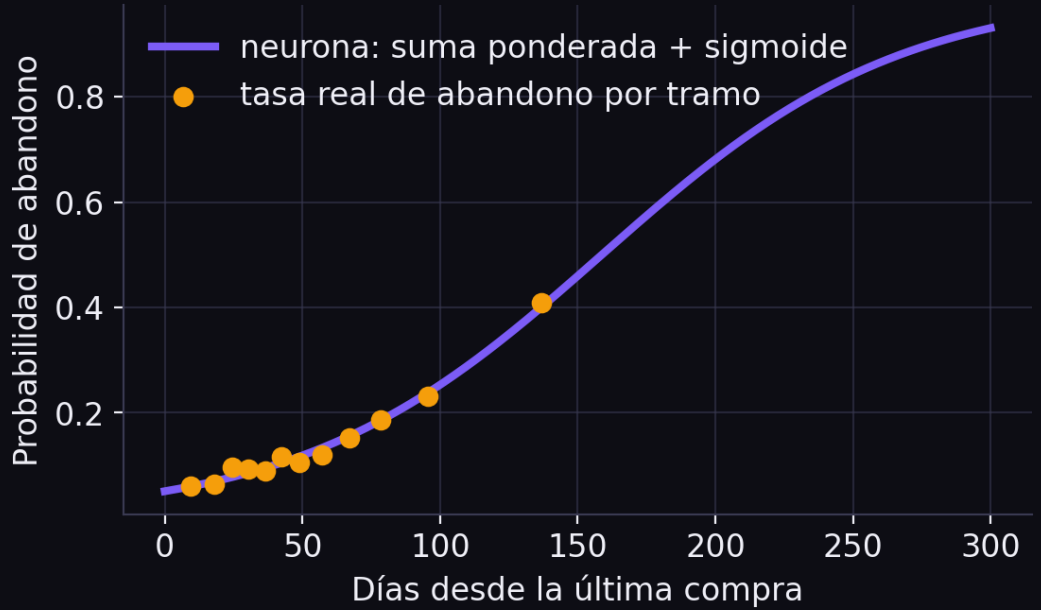
→

Pérdida
Qué tan mal acertó

NovaRetail
21 entradas → 16 → 8 → 1
497 parámetros

Regresión logística
21 entradas → 1
22 parámetros

Una neurona a mano



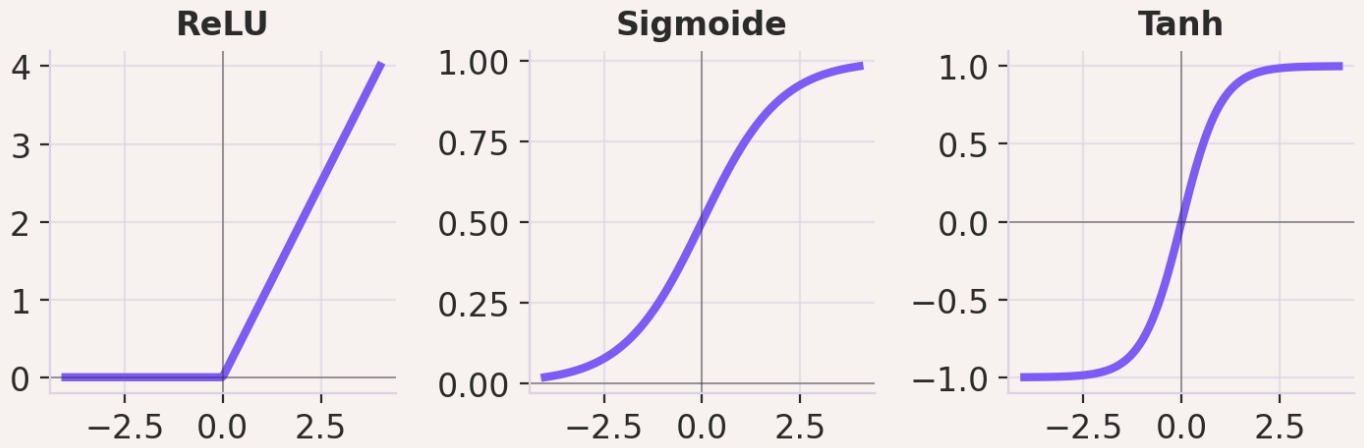
1 · Multiplica
cada entrada por un peso

2 · Suma
y agrega un sesgo

3 · Activa
con una función no lineal

Con una entrada, la neurona es una regresión logística.

Funciones de activación



ReLU
Deja pasar lo positivo y anula lo negativo

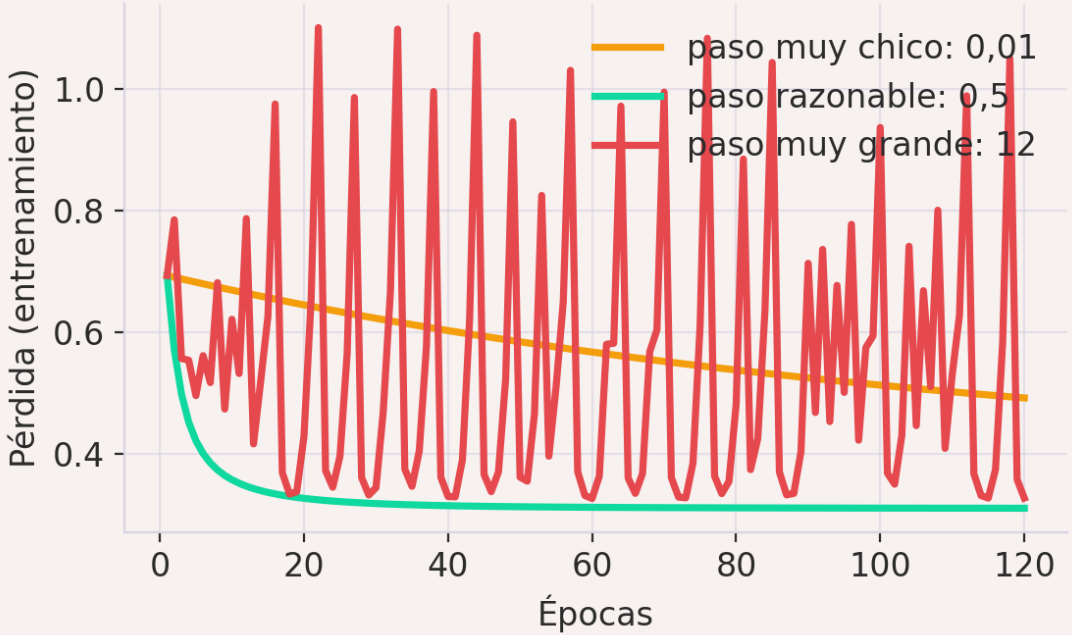
Sigmoide
Valor entre 0 y 1: una probabilidad

Tanh
Valor entre −1 y 1

Entrenar una red



Learning rate y épocas



Muy chico
Baja, pero tarda: a las 120 épocas, 0,49

Razonable
Se asienta en 0,31

Muy grande
Rebota hasta 1,10 y no se asienta

Sobreajuste y detención temprana

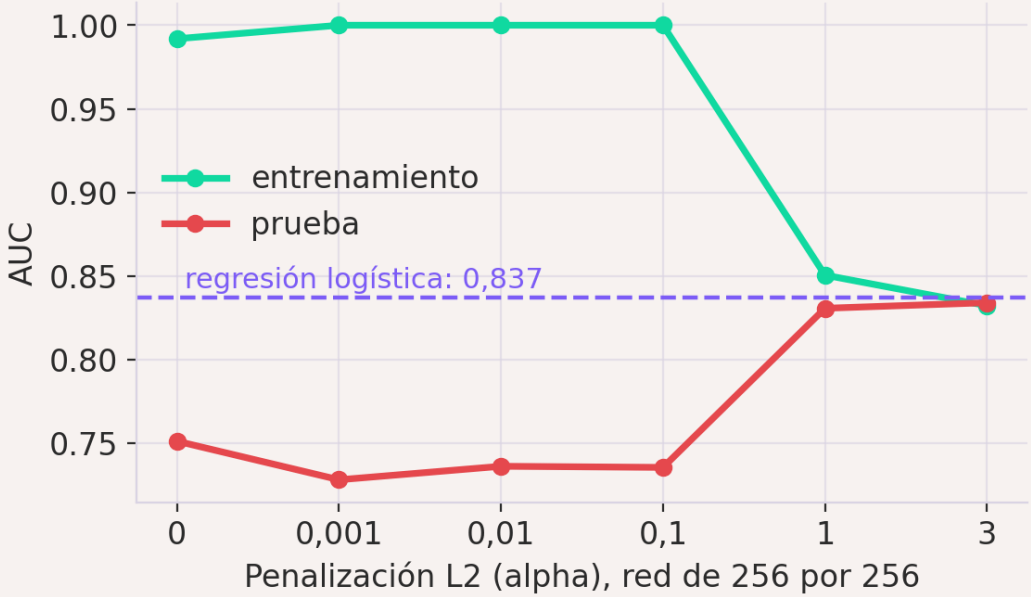


Red (64, 32)
La validación toca fondo en la época 4 y después empeora

Red grande (256, 256)
AUC 0,992 en entrenamiento y 0,751 en prueba

XGBoost profundo
1,000 en entrenamiento y 0,792 en prueba

Cómo frenar el sobreajuste



Penalización L2
Con alpha = 3 la brecha se cierra: 0,832 y 0,834

Detención temprana
Parar cuando la validación deja de mejorar

Dropout
Apagar neuronas al azar mientras se entrena

Un método, dos casos

CASO 1 · NOVARETAIL

La regla de abandono es casi una logística.

8.000 clientes · 14,3 % de abandono.

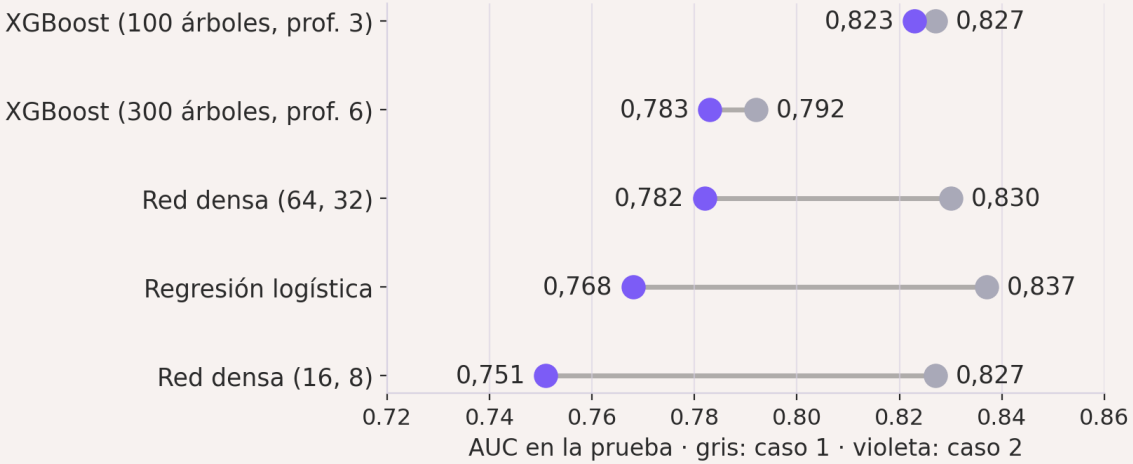
CASO 2 · NOVARETAIL 2

Los mismos clientes y tres variables nuevas.

Umbral, interacción y efectos que no son una línea. Techo de AUC: 0,841.

Tres modelos en cada caso: regresión regularizada, red densa pequeña y XGBoost.

El resultado



Caso 1
Gana la regresión: 0,837

Caso 2
Gana XGBoost: 0,823, cerca del techo de 0,841

La red
No gana en ninguno: 0,830 y 0,782

Costo y opacidad



Tamaño
22 parámetros contra 497 o más, o cientos de árboles

Qué miran
Los modelos miran lo mismo: días desde la última compra, segmento Esencial y falta de satisfacción

Variables nuevas
Sin efecto en el caso 1; en el caso 2, XGBoost pasa de 0,805 a 0,823

Qué arquitectura para qué dato

Dato	Familia	Ejemplo
Imagen	Red convolucional	Productos dañados en las fotos de una devolución
Secuencia	Red recurrente	Ventas de la próxima semana por producto
Texto	Transformer	Clasificar los reclamos por motivo
Tabular	Regresión o árboles; la red, solo si compara bien	Abandono de clientes
Generar	Modelo generativo	Asistente de atención al cliente

Redes convolucionales

Imagen
Píxeles

→

Filtros
Buscan bordes y formas

→

Mapa de rasgos
Dónde aparece cada forma

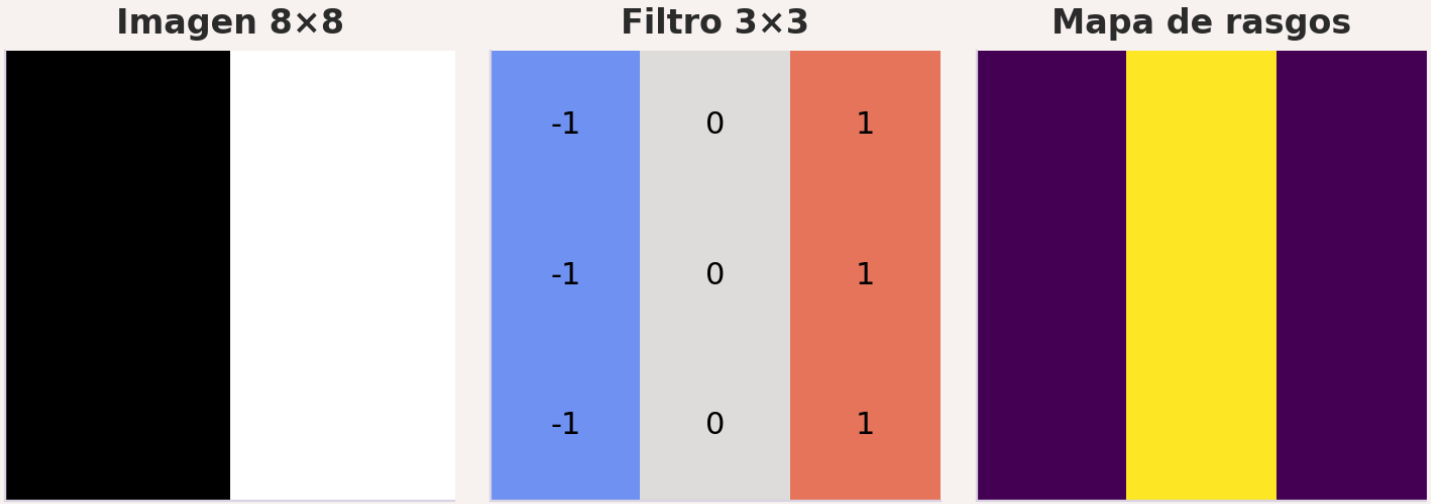
→

Clasificación
Qué es

Capa densa de 784 a 128
100.480 parámetros

Convolución de 16 filtros de 3×3
160 parámetros

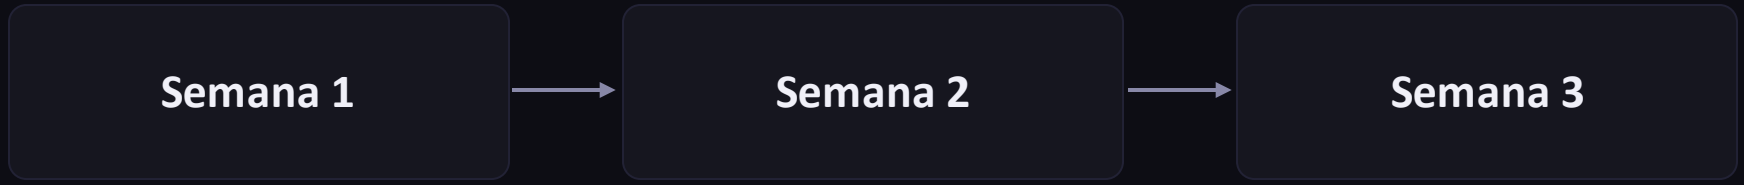
Una convolución a mano



El mismo filtro recorre toda la imagen

Responde solo donde hay un borde vertical

Redes recurrentes

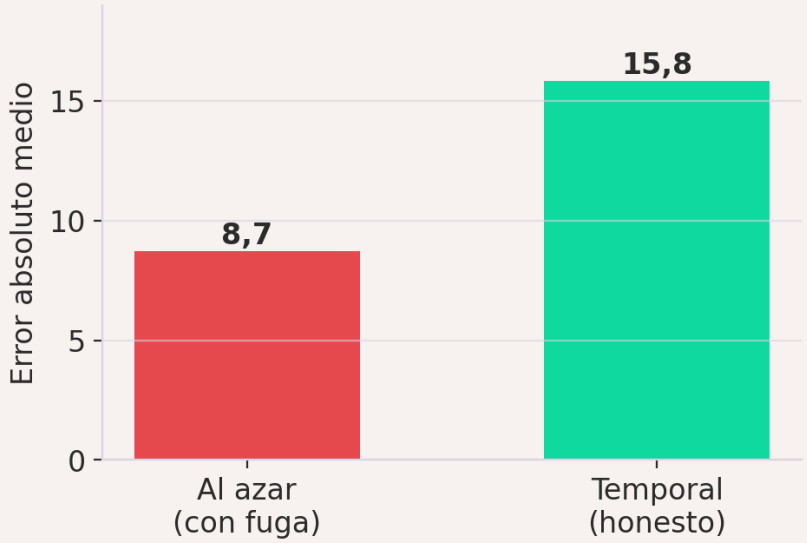


El estado viaja de un paso al siguiente: lo que la red recuerda

El orden importa
Cambiar el orden cambia el resultado

El problema
En secuencias largas se olvida lo lejano

Secuencias: la fuga del orden



Al azar
Error 8,7: parece mejor porque el modelo ya vio el futuro

Temporal
Error 15,8: el número honesto

La regla
Si hay orden, se divide por tiempo

Serie semanal sintética con tendencia y estacionalidad.

Transformers

Palabras

«el cliente dejó de comprar»

→

Atención

Cada palabra mira a las demás

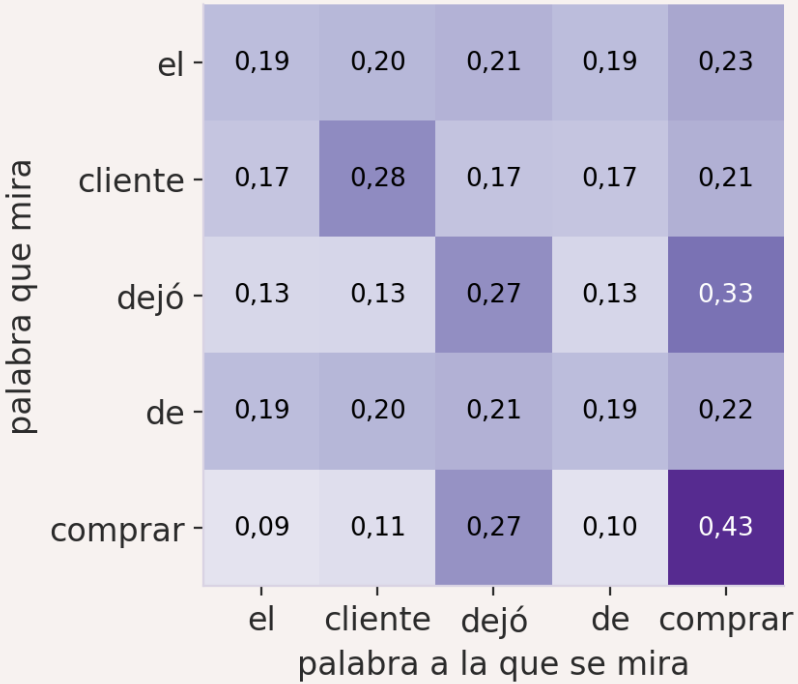
→

Representación

Cada palabra con su contexto

En la práctica se suele reutilizar un modelo preentrenado.

La atención a mano



Cómo se calcula
Se comparan las palabras de a pares y se normaliza con softmax

Qué muestra
«comprar» mira más a sí misma (0,43) y a «dejó» (0,27)

Ojo
Vectores de ejemplo, no un modelo entrenado

Modelos generativos

Qué generan

Texto, imágenes y datos sintéticos.

Para qué sirven

Asistentes, borradores y datos de prueba.

Qué riesgos traen

Respuestas inventadas, datos sensibles y costo por consulta.

Un modelo generativo suena seguro aunque se equivoque.

Reutilizar o entrenar

REUTILIZAR UN MODELO PREENTRENADO CUANDO…

Hay pocos datos etiquetados.

La tarea se parece a un uso general.

El costo de entrenar no se justifica.

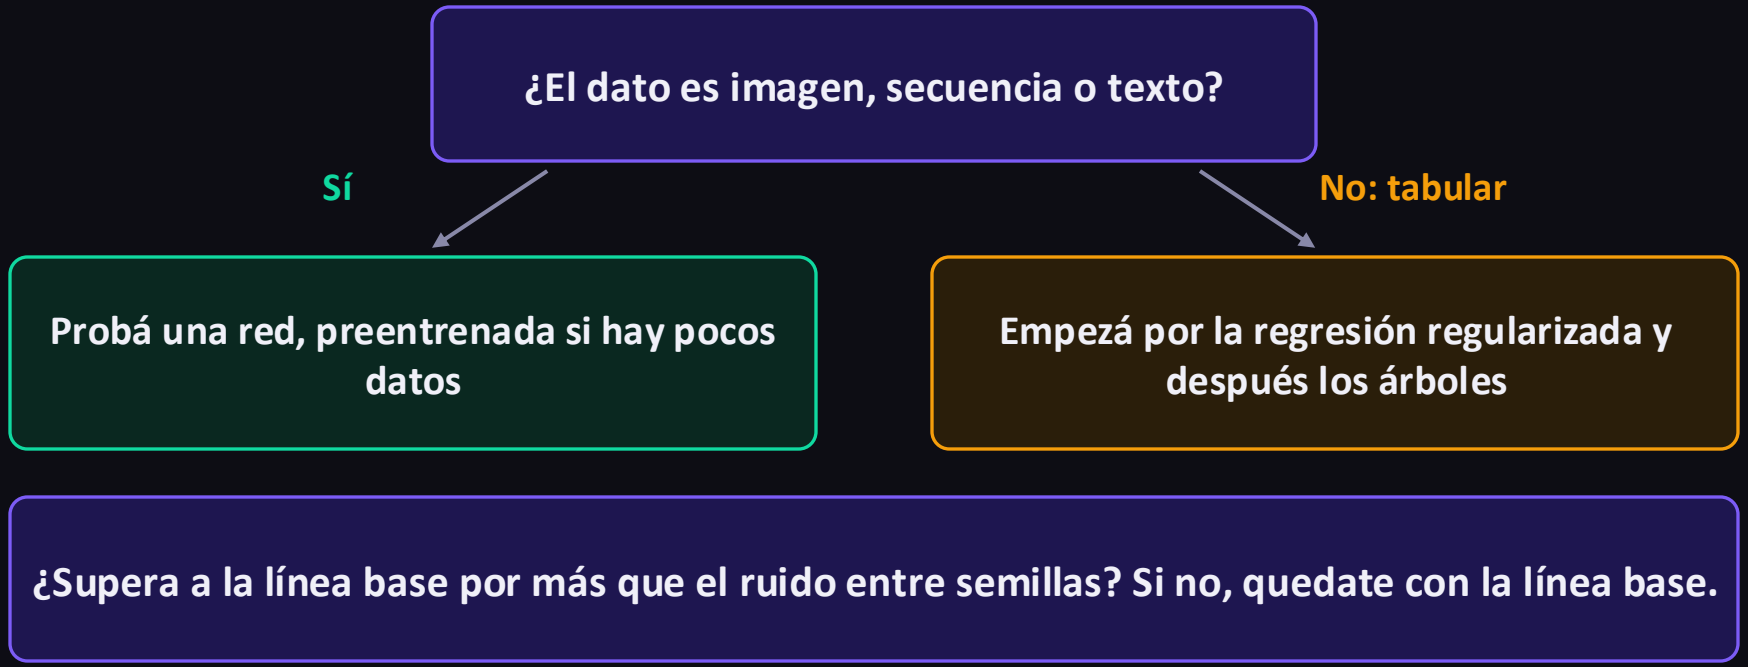
ENTRENAR UNO PROPIO CUANDO…

El dominio es muy particular.

Hay muchos datos propios.

Los datos no pueden salir de la organización.

Cómo elegir una arquitectura



Cuatro problemas, una arquitectura

1 Leé tus cuatro problemas

Imagen, secuencia, texto y tabular.

2 Elegí la arquitectura

Red convolucional, recurrente, transformer o modelo clásico.

3 Completá datos, métrica y riesgo

Y por qué esa elección.

Siete equipos, cuatro problemas cada uno: tu tarjeta tiene los tuyos.

A los 8 minutos: primer mapeo

A los 15: intercambio con otro equipo

Las cuatro modalidades

Modalidad	Arquitectura	Datos que hacen falta	Métrica	Riesgo típico
Imagen	Red convolucional	Muchas imágenes etiquetadas	Recall y precisión	Pocos ejemplos de lo raro
Secuencia	Red recurrente	Historia ordenada en el tiempo	Error medio	Fuga al mezclar el tiempo
Texto	Transformer	Textos etiquetados o un modelo preentrenado	F1 por clase	Sesgo por lenguaje
Tabular	Regresión o árboles	Variables por cliente	AUC y costo del error	Fuga de variables

Puesta en común

1 Dos soluciones

Dos equipos muestran el mismo tipo de problema con supuestos distintos.

2 Qué cambia

¿Qué dato, métrica o riesgo hace cambiar la arquitectura?

3 Qué evidencia decidiría

¿Qué comparación nos haría cambiar de idea?

Cada problema admite más de una familia válida: lo que cuenta es la justificación.

Seis errores frecuentes

Error	Qué pasa	Cómo se evita
Elegir por moda	Costo y opacidad sin ganar nada	Partir de la línea base
Entrenar sin línea base	No se sabe si la red aporta	Probar primero el modelo simple
Mezclar el tiempo	El resultado se infla	Dividir por tiempo
Mirar solo el entrenamiento	0,992 en entrenamiento y 0,751 en prueba	Validación aparte y detención temprana
Una sola semilla	Una red chica va de 0,744 a 0,819	Repetir y reportar el rango
Omitir costo, sesgo y explicabilidad	Gana por poco pero cuesta más	Ponerlos en el canvas

Buenas prácticas

1 Línea base primero
Un modelo simple, siempre.

2 Misma partición
Y misma métrica para todos.

3 Varias semillas
Reportá el rango.

4 Mirá las dos curvas
Entrenamiento y validación.

5 Detención temprana
Parar a tiempo.

6 Dividí por tiempo
Si los datos tienen orden.

7 Anotá el costo
Tiempo y parámetros.

8 Probá una variable
Antes de un modelo más grande.

El desafío: cómo se trabaja

1 Conduce

Cuida el tiempo y el foco.

2 Completa

Escribe el canvas.

3 Valida

Pregunta qué falta probar.

4 Presenta

Defiende en 3 minutos.

Diseñan un experimento para su aplicación. No hace falta entrenar un modelo grande.

Siete equipos, siete aplicaciones.

DESAFÍO

Siete equipos, siete aplicaciones

1 · Abandono de clientes

Tabular: pocos casos positivos.

2 · Demanda semanal

Secuencia: división temporal.

3 · Reclamos por texto

Texto: pocos datos etiquetados.

4 · Productos devueltos

Imagen: pocas imágenes dañadas.

5 · Recomendación

Secuencia: dominan los más vendidos.

6 · Operaciones sospechosas

Tabular: muy pocos casos.

7 · Asistente generativo

Generativo: respuestas inventadas.

Para todos

¿La red mejora a la línea base?

DESAFÍO

El canvas de experimento

1 Línea base

Qué modelo simple hay que superar.

2 Arquitectura

Cuál, y por qué es proporcional.

3 Split

Cómo se evita la fuga y el sesgo.

4 Criterio de detención

Cuándo se corta el entrenamiento.

5 Métrica

Por qué sirve para el costo del error.

6 Costo

De entrenar y de operar.

7 Revisión ética

Quién puede salir perjudicado.

8 Condición de abandono

Cuándo se descarta la red.

DESAFÍO

Las cinco preguntas

1	¿Qué decisión mejora?	Qué se hace distinto con el resultado.
2	¿Para qué población?	Quién entra y quién queda afuera.
3	¿Hay fuga o sesgo?	Qué sabe el modelo que no debería saber.
4	¿Cómo se valida?	Qué partición, qué métrica y cuántas semillas.
5	¿Cuándo se abandona?	Qué resultado haría descartar la red.

DESAFÍO

Criterios de calidad

1 Línea base explícita
Dice qué simple hay que superar.

2 Pregunta definida
¿La red mejora a la línea base?

3 Split sin fuga
Honesto con el tiempo y los grupos.

4 Métrica con sentido
Atada al costo del error.

5 Costo declarado
Tiempo, parámetros y operación.

6 Riesgo nombrado
Sesgo, privacidad y explicabilidad.

7 Condición de abandono
Cuándo se descarta la red.

DESAFÍO

Defensa y revisión cruzada

Grupo A
Tabulares
Equipos 1 y 6

Grupo B
Secuencias
Equipos 2 y 5

Grupo C
Texto, imagen y generativo
Equipos 3, 4 y 7

3 minutos de presentación, 2 de preguntas y una devolución escrita con la lista de criterios.

Cierra un plenario de 5 minutos: una decisión que cambió por la revisión.

Qué me llevo y qué dejo escrito

CUATRO IDEAS

1. Primero la línea base.
2. Depende de la estructura de los datos.
3. En tablas, probá árboles antes que una red.
4. Costo, explicabilidad y riesgo también cuentan.

TICKET DE SALIDA · UNA FRASE POR CADA UNO

Qué voy a repetir

Qué voy a verificar

Qué voy a dejar de hacer

Hacia la clase 4

Hoy: una red es una comparación, no un fin

→

¿Qué hace falta para llevarlo a producción?

- **Experimentación**
- **Producción**

Eso introduce la clase 4: de modelo experimental a producción.

DIGITALHOUSE

ARCA | AGENCIA DE RECAUDACIÓN Y CONTROL ADUANERO

PREGUNTAS Y RESPUESTAS

Q&A

¿Qué dudas, casos o ideas quedaron?

¡Muchas gracias!

Laura Sol Franco · Digital House

Programa Profesional: Científico de Datos (Data Scientist) — ARCA