DIGITALHOUSE CLASE EN VIVO 4

ARCA | AGENCIA DE RECAUDACIÓN Y CONTROL ADUANERO

De modelo experimental a producción

Clase en vivo 4 · 120 minutos

Programa Profesional: Científico de Datos (Data Scientist) — ARCA

Escaneá el QR para registrar tu asistencia

Me presento...

1. Directora General en The eLabs: transformación digital e integración de IA.
2. Host del podcast Hack The Future: estrategia y liderazgo, no solo algoritmos.
3. Docente en la Maestría en Ciencia de Datos (Univ. Austral), ITBA y Di Tella.



Apasionada por aplicar IA para mejorar la productividad y las decisiones.

REPASO

Lo que traés del curso

1 Módulo 8 · A producción

Notebooks, estructura de un proyecto, APIs y despliegue.

2 Módulo 7 · Superset

Introducción, visualización analítica y dashboards: al final, para ver lo que pasa.

3 Para decidir

Un servicio se construye con un contrato, no con un archivo.

Problemas de los notebooks · Estructura de un proyecto · APIs para modelos · Despliegue · Dashboards

¿Qué decisión deberías poder tomar al final de la clase, y qué dato no alcanzaría?

La pregunta de la clase

¿Qué debe cambiar para que una predicción útil en un notebook sea confiable cuando otra aplicación la consume?

Un contrato	**Una versión**	**Un registro**	**Una prueba**	**Un tablero**

Cinco hipótesis: las vamos a poner a prueba.

Qué vamos a lograr hoy

PROPÓSITO

Transformar un notebook en un servicio con contrato, validación, observabilidad y tablero.

EVIDENCIA DE SALIDA

Un contrato auditado, un modelo revisado con su cambio propuesto y un tablero corregido.

Siete equipos: cada uno revisa una pieza distinta de la ruta a producción.

NovaRetail: dónde estamos

8.000 clientes

Con un 14,3 % de abandono a 90 días.

AUC 0,837

La regresión logística, en la prueba.

Ahora, el CRM

Va a llamar al modelo en cada ticket.

El modelo ya anda en el notebook. Falta que otra aplicación pueda confiar en él.

Primero, revisá el modelo

1 ¿Mejora a una referencia?

Contra la solución más simple, no contra nada.

2 ¿Es confiable?

Sus probabilidades se parecen a lo que pasa; no solo ordenan.

3 ¿Funciona en cada segmento?

Un promedio puede esconder a un grupo.

4 ¿Qué cuesta llevarlo?

Latencia, mantenimiento y explicación.

En la clase 3, una red neuronal no mejoró a la regresión: llevar un modelo a producción cuesta más que entrenarlo.

¿Qué versión llevamos?

Métrica, en la prueba	v1 · regresión	v2 · boosting
AUC	0,837	0,830
Brier (menor es mejor)	0,092	0,093
Probabilidad media (observado: 14,3 %)	14,3 %	14,2 %
Abandonos capturados en el 20 % de mayor riesgo	60,5 %	60,5 %
AUC · segmento Esencial	0,766	0,762
AUC · segmento Plus	0,781	0,760
AUC · segmento Premium	0,861	0,850

La v2 no mejora a la v1 en ninguna medida: la v1 va a producción y la v2 queda como candidata.

Experimentar no es producir

	Experimentación	Producción
Quién lo usa	Quien escribió el código	Otra aplicación, que no sabe de ciencia de datos
Qué datos recibe	Una tabla fija y ya limpia	Pedidos nuevos, a veces incompletos
Cuándo corre	Cuando alguien lo ejecuta	Todos los días, a cualquier hora
Si falla	Se vuelve a correr	Una decisión sale mal y se nota tarde
Qué se guarda	El archivo del modelo	Versión, entrada y resultado de cada pedido

El notebook tal cual

1 Depende del orden

Los datos entran por posición, no por nombre.

2 Estado compartido

Usa variables que solo existen en el notebook.

3 Sin validación

Acepta lo que llegue, aunque no tenga sentido.

4 Sin versión

Nadie sabe qué modelo respondió.

5 Todo junto

Carga, transformación e inferencia, en el mismo lugar.

Predecí: dos campos cambiados

Datos en el orden correcto
0,31

→

Dos campos intercambiados
0,74

No da ningún error: da otra respuesta.

El mismo cliente, el mismo modelo, dos probabilidades.

Cinco responsabilidades separadas

Carga del artefacto
Trae la versión del modelo

→

Esquema
Dice qué entra y con qué rango

→

Transformación
Arma las variables como al entrenar

→

Inferencia
Calcula la probabilidad

→

Respuesta
Devuelve resultado o error claro

Cada responsabilidad se prueba y se cambia por separado.

Estructura de un proyecto de ML

```
proyecto-abandono/
├─ datos/              datos y diccionario
├─ notebooks/          la exploración
├─ paquete/
│  ├─ entrenar.py     entrena y guarda
│  ├─ transformar.py las variables, una vez
│  └─ servicio.py     valida, puntúa, responde
├─ contrato/           contrato-api.yaml
├─ pruebas/            las cinco pruebas
└─ registro/           versiones y fichas
```

CADA CARPETA RESPONDE

¿De dónde vienen los datos?

¿Cómo se entrena?

¿Cómo se sirve?

¿Cómo se prueba?

¿Qué versión corre?

Datos, entrenamiento e inferencia

Datos

Se cargan y se versionan

Entrenamiento

Corre pocas veces y produce un artefacto

Inferencia

Corre siempre y consume el artefacto

Las mismas transformaciones, en el entrenamiento y en la inferencia.

La ruta completa

Notebook
Control: validar con clientes nuevos

→

Paquete
Control: un solo pipeline

→

API
Control: contrato y errores 422

→

Registro
Control: versión y entrada

→

Dashboard
Control: un responsable

Una etapa sin control es la que falla sin que nadie se entere.

Anatomía de un contrato

Parte	Qué dice	Ejemplo
Qué entra	Campos, tipos, rangos y valores permitidos	edad: número de 18 a 100
Qué sale	La probabilidad y la versión que respondió	probabilidad, version_modelo
Qué errores hay	Cuándo se rechaza un pedido y qué se informa	422, con campo y motivo
Qué versión es	El contrato también se versiona	la ruta /v1/predict

El borrador y su auditoría

```
paths:
  /predict:              ← sin versión
components:
  PrediccionRequest:
    required: [id_cliente]   ← solo el id
    properties:
      edad: {type: number}   ← sin rango
      segmento: {type: string} ← texto libre
      canal: {type: string}
    (sin additionalProperties)
responses: 200 y 500       ← sin 422
```

AUDITORÍA DEL BORRADOR

- ✗ Campos obligatorios
- ✗ Rechaza campos que no conoce
- ✗ Rangos en los números
- ✗ Valores permitidos en los textos
- ✗ Versión en la ruta
- ✗ Define el error 422
- ✗ Informa la versión del modelo
- ✗ Incluye un ejemplo

Predecí: solo el id

Pedido	Status	Probabilidad
Pedido completo	200	0,040
Sin región ni segmento	200	0,091
Sin los días desde la última compra	200	0,033
Solo el id del cliente	200	0,258
Edad = 150	200	0,027
Segmento «Gold», que no existe	200	0,051
compras_12m = «muchas»	422	—

Catorce pedidos de prueba

Contrato borrador
11 de 14

Contrato revisado
0 de 14

Pedidos mal resueltos, sobre catorce con respuesta conocida.

El contrato revisado

1. Campos obligatorios para todo lo que usa el modelo
2. Se rechazan los campos desconocidos
3. Rango en edad, días y descuento
4. Valores permitidos en canal, segmento y región
5. La versión en la ruta: /v1/predict
6. El error 422, con campo y motivo
7. La versión del modelo en la respuesta
8. Un ejemplo de pedido válido

El modelo no cambia: cambia lo que el servicio acepta.

Un valor imposible, dos respuestas

CON EL BORRADOR

status: 200
probabilidad: 0,027
(sobre un cliente de 150 años)

CON EL REVISADO

status: 422
campo: edad
motivo: mayor que 100

Un 422 que explica es un hallazgo; un 200 inventado es un artefacto.

Códigos de error

Código	Cuándo	Qué dice
200	Todo salió bien	La probabilidad y la versión que respondió
422	El pedido no cumple el contrato	Qué campo falló y por qué
500	Falló el servicio	Un mensaje genérico, sin detalles internos

PRÁCTICA GUIADA

Auditá el contrato

1 Leé el contrato

Abrí contrato-api.yaml: required, properties y responses.

2 Probá pedidos

Cambiá una cosa por vez y mirá qué responde.

3 Escribí tus hallazgos

Tres pruebas y dos métricas operativas.

A los 8 minutos: mostrá un pedido que el contrato acepta y no debería.

A los 15: intercambiá el trabajo y pedí una observación concreta.

Se evalúa el razonamiento, no la velocidad.

Tres pruebas y dos métricas

UNA PRUEBA

Pedido: sin dias_desde_ultima_compra.

Espero: 422.

Porque: el modelo necesita ese dato y no debería inventarlo.

UNA MÉTRICA OPERATIVA

Porcentaje de pedidos rechazados, por campo.

Dice si el servicio funciona, no si el modelo es bueno.

PUESTA EN COMÚN

Dos soluciones, dos supuestos

Qué rechaza

¿Cada rechazo protege una decisión?

Qué acepta con aviso

¿Un canal nuevo se rechaza o se puntúa avisando?

Qué evidencia decide

¿Cómo elegirías entre las dos?

Dos soluciones distintas pueden ser válidas: ¿qué evidencia permitiría elegir?

Versionar modelo y contrato

Campo de la ficha	Qué guarda
version	v1, v2: única e inmutable
algoritmo	Regresión logística o boosting de árboles
auc_prueba	0,837 la versión 1 y 0,830 la versión 2
hash_datos_entrenamiento	Una huella de los datos con que se entrenó
semilla	Para reproducir lo que sea aleatorio
version_contrato	Qué contrato respeta
aprobado_por y fecha	Quién la dejó pasar a producción y cuándo

Cada predicción deja un registro

1 Cuándo

Timestamp y un identificador del pedido.

2 Qué versión

Del modelo y del contrato.

3 La entrada

Con retención y acceso definidos.

4 El resultado

Probabilidad y status.

5 La latencia

Cuánto tardó en responder.

Lo que no se guarda no se reproduce; lo que se guarda sin criterio es un riesgo.

La prueba de humo

Casos de la prueba	Versión sana	Versión rota	¿La atrapa?
Clientes típicos	0,019	0,019	No: pasa igual
Casos de borde	0,288	0,891	Sí, pero bloquea la sana con poca tolerancia
Una mezcla	0,047	0,439	Sí, con una tolerancia de 0,15

Diferencia máxima frente a la versión en producción.

El error que cambia la conclusión

CON CLIENTES TÍPICOS

Tolerancia 0,05
La versión rota pasa
Se promueve un defecto

CON UNA MEZCLA

Tolerancia 0,15
La prueba falla
Se vuelve a la versión 1

No cambió el modelo ni el defecto: cambió qué clientes hay en la prueba.

El rollback, decidido de antemano



Una marcha atrás que depende de que alguien se dé cuenta no es un plan.

Latencia: individual o por lotes

Situación	Decisión	Resultado
CRM, 40 pedidos por segundo	Individual	p95 de unos 38 ms
CRM esperando un lote de 50	Por lotes	La espera supera el medio segundo
Proceso nocturno, 8.000 clientes	Lotes de 200	Termina en unos 4 segundos
Proceso nocturno, un solo lote	Lote de 8.000, timeout de 2 s	Falla: la llamada tarda más de 3 s
Un pico de cinco veces el volumen	Autoescalado	Hace falta más capacidad

Drift: qué cambió y cuándo te enterás

Señal	Avisa a los	Qué dice
Pedidos rechazados (422)	2 días	Apareció un valor que el contrato no conoce
PSI de los días desde la última compra	5 días	Cambió la distribución de una variable
AUC con resultados reales	106 días	El modelo empeoró, pero tarde

La deriva empieza el día 60; el abandono real se conoce a los 90 días.

Buenas prácticas para producción

Separar

Datos, entrenamiento e inferencia.

Un solo pipeline

Para entrenar y para servir.

Un contrato

Que rechaza lo que no entiende.

Versionar

Modelo y contrato.

Un registro

De cada predicción.

Humo con borde

Casos típicos y de borde.

Rollback

Decidido de antemano.

Un tablero

Mínimo y con responsable.

Pausa y volvemos

Ejercicio 1

Tirar abajo un modelo y proponer el cambio.

Ejercicio 2

Corregir un tablero aplicando buenas prácticas.

Volvemos con los equipos armados y las tarjetas a mano.

MLOps: lo que pasa después de entrenar

Entrenar y evaluar
Con datos versionados y una referencia

→

Registrar
Cada versión, con su ficha

→

Desplegar
Detrás de un contrato y con prueba de humo

→

Monitorear
Entradas, salidas y resultados reales

→

Decidir
Reentrenar o volver a la versión anterior

Es un conjunto de prácticas, no una herramienta: el modelo cambia y todo lo que lo rodea también.

Dos ejercicios de 15 minutos

EJERCICIO 1 · TIRÁ ABAJO EL MODELO

Un modelo o un servicio, con su evidencia.

Tres problemas, el cambio que proponés y la evidencia para aprobarlo.

No se implementa nada.

EJERCICIO 2 · CORREGÍ EL TABLERO

Un tablero por equipo, con malas prácticas.

Cambiá la configuración y mirá al revisor.

Tres correcciones, con su porqué.

Conducción

Cuida el tiempo y el foco.

Validación

Pide la evidencia.

Presentación

Cuenta en 2 minutos.

Nadie llega a hacerlo todo: importa el criterio.

EJERCICIO 1

Tirá abajo el modelo

1 · El contrato de entrada

Un contrato que solo exige el id.

2 · Versionado y registro

Un registro que no permite reproducir.

3 · Humo y rollback

Una prueba que deja pasar el error.

4 · Latencia bajo carga

Lotes que esperan y un timeout que no alcanza.

5 · Drift y monitoreo

Una sola señal, sin responsable.

6 · Fuga y consistencia

Un AUC perfecto en la prueba.

7 · El tablero mínimo

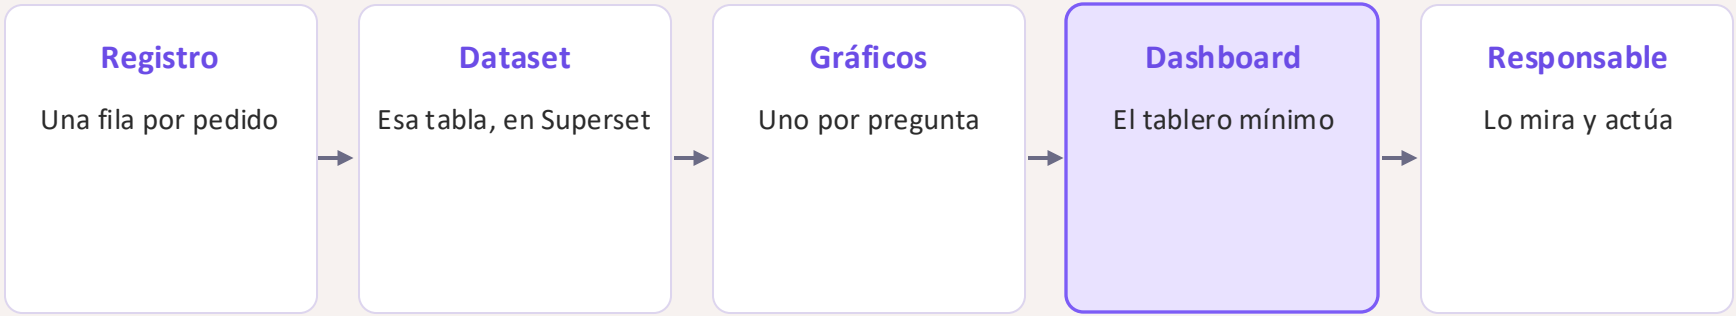
Tres paneles que no avisan de nada.

Para todos

Tres problemas, el cambio y la evidencia.

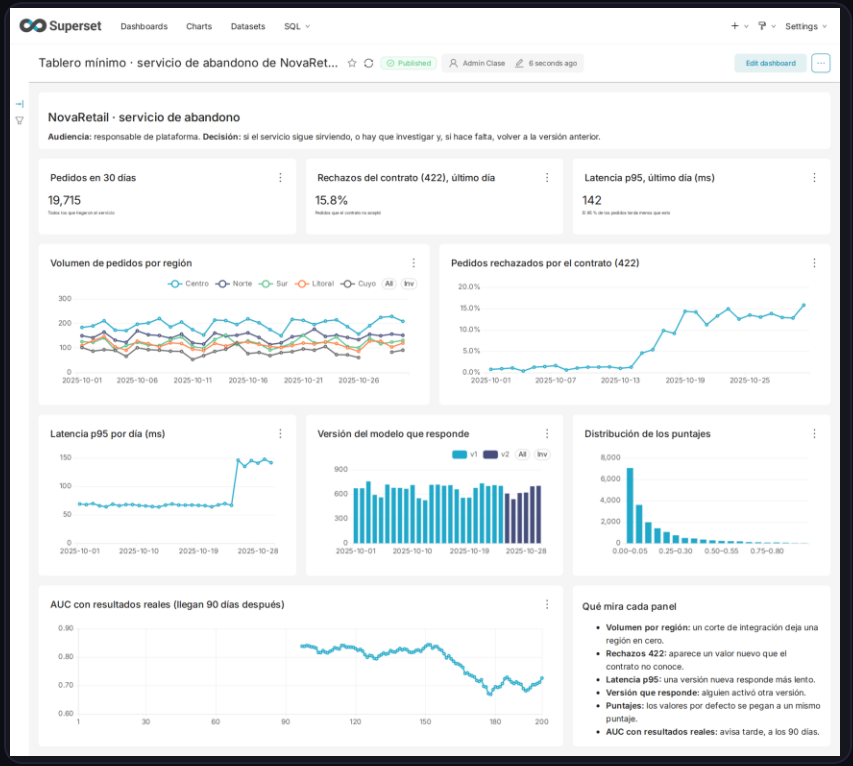
Se argumenta el cambio y la evidencia que lo aprobaría. No se implementa.

Del registro al dashboard en Superset



Un tablero que nadie mira es decoración: cada panel lleva una acción y un dueño.

Así se ve el tablero mínimo en Superset

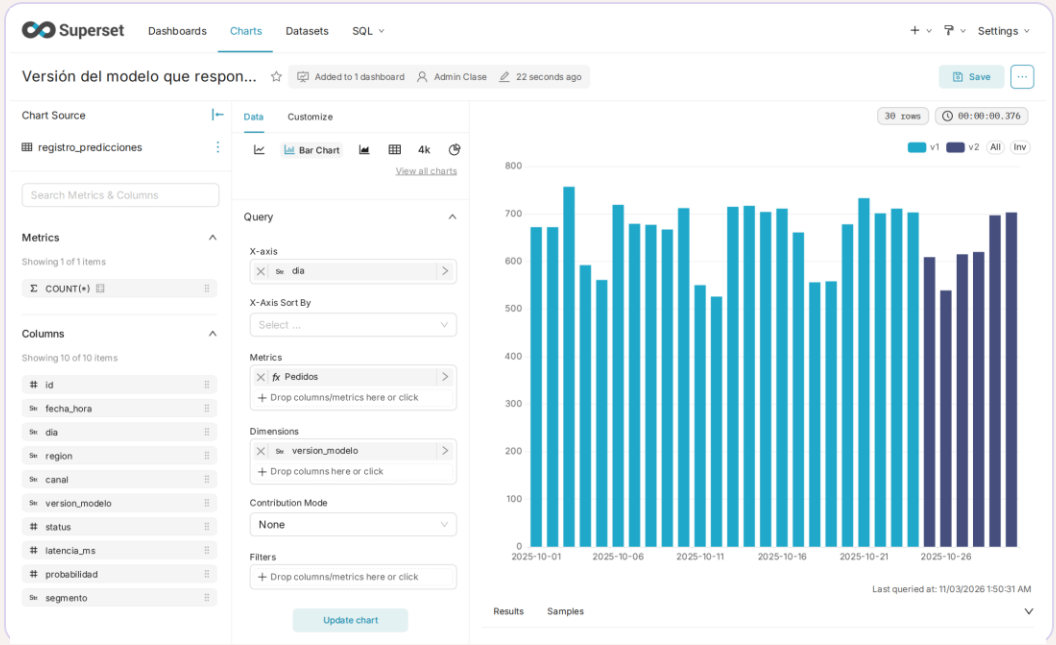


QUÉ MUESTRA CADA PANEL

- Volumen por región: Cuyo desaparece el 27 y el 28.
- Rechazos del contrato: de 0,7 % a 15,8 % desde el 15, por un canal nuevo.
- Latencia p95: de unos 67 a unos 145 ms el día 25.
- Versión que responde: la v2 entra el 25, sin aviso.
- Puntajes: lo que devuelve el modelo, en rangos.
- AUC con resultados reales: cae, pero avisa a los 90 días.

Seis paneles cubren los siete incidentes que ya pasaron.

Cómo se arma: de la tabla al gráfico



1 Conectar la base

Una conexión a SQLite con el registro.

2 Crear el dataset

Una tabla del registro de pedidos.

3 Armar el gráfico

Tipo, métrica y dimensión.

4 Sumarlo al dashboard

Y ordenarlo, de arriba hacia abajo.

El script de la demo carga la conexión, los datasets y los gráficos; en el ejercicio 2, cada equipo corrige un tablero.

EJERCICIO 2

Buenas prácticas de visualización

Un título que informa

Qué se mira, de qué período, en qué contexto.

Unidad y fuente

En qué se mide y de dónde sale.

Barras desde cero

Un eje recortado exagera.

El gráfico justo

Una torta de veinte porciones no se lee.

Cada porcentaje, su base

Sobre cuántos casos.

Color que se distingue

Sin depender del rojo y el verde; con leyenda.

Los hechos, marcados

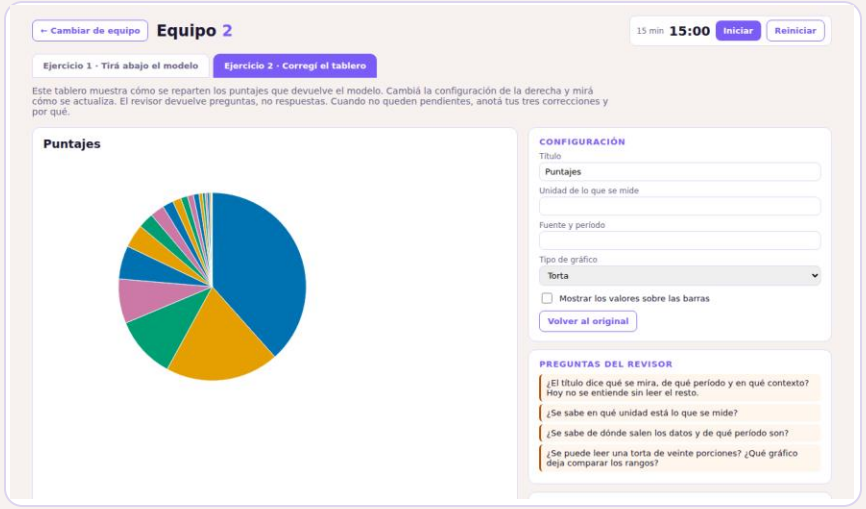
Cuándo cambió algo.

Sin esconder con promedios

Un promedio móvil puede ocultar.

EJERCICIO 2

Corregí el tablero



Antes: una torta de veinte porciones



Después: barras, con título, unidad y fuente

Abrí el link de la clase, elegí tu equipo y corregí tu tablero: cambiá la configuración y mirá al revisor.

Errores que se observan

1 El notebook tal cual

Empaquetarlo sin separar responsabilidades.

2 Campos extra en silencio

Aceptar lo que el contrato no conoce.

3 Entrenar e inferir mezclados

Variables armadas distinto en cada lado.

4 Sin versión

Nadie sabe qué modelo respondió.

5 Métricas sin contexto

Sin ventana, sin población, sin base.

Contar y ser revisado

Cuenta

2 minutos: qué tiró abajo y qué corrigió

Pregunta el equipo revisor

Una pregunta: técnica, de negocio o de riesgo

Una fortaleza

Lo que está bien sostenido.

Una brecha prioritaria

Lo que más cambia la conclusión.

Una mejora verificable

Algo que se pueda comprobar.

CIERRE

Qué me llevo y qué dejo escrito

CUATRO IDEAS PARA LLEVARSE

1. **Un contrato que rechaza**
   Mejor un 422 que un 200 inventado.
2. **Una versión en cada respuesta**
   Del modelo y del contrato.
3. **Una prueba con casos de borde**
   Y un rollback decidido de antemano.
4. **Un tablero que avisa**
   Con una acción y un responsable.

TICKET DE SALIDA

Qué repetiría

Lo que mejor funcionó.

Qué verificaría

Lo que todavía no comprobé.

Qué no llevaría todavía

Lo que no está listo para producción.

LO QUE VIENE

Hacia el proyecto final

Hoy: una ruta a producción, con evidencia

→

Clase 5: defender el proyecto completo

Problema y datos	Modelo y validación	Operación y decisión	ficha-proyecto-final.md

Lo que escribieron hoy es la base de la ficha del proyecto final.

DIGITALHOUSE

ARCA | AGENCIA DE RECAUDACIÓN Y CONTROL ADUANERO

PREGUNTAS Y RESPUESTAS

Q&A

¿Qué dudas, casos o ideas quedaron?

¡Muchas gracias!

Laura Sol Franco · Digital House

Programa Profesional: Científico de Datos (Data Scientist) — ARCA