

Python aplicado a Ciencia de Datos

Clase en vivo 1 · 120 minutos

Programa Profesional: Científico de Datos

(Data Scientist) — ARCA



Me **presento...**

1

Directora General en The eLabs: transformación digital e integración de IA.

2

Host del podcast Hack The Future: estrategia y liderazgo, no solo algoritmos.

3

Docente en la Maestría en Ciencia de Datos (Univ. Austral), ITBA y Di Tella.



Laura Sol Franco

CEO at The eLabs | Applied AI, Data, Risk & Future of Work



Apasionada por aplicar IA para mejorar la productividad y las decisiones.

Qué vamos a lograr hoy

PROPÓSITO

Construir un pipeline reproducible de exploración, limpieza y variables para explicar el abandono.

RESULTADO OBSERVABLE

Notebook reproducible: auditoría, dos transformaciones, una visualización, un hallazgo y su límite.



Retomamos los módulos 1 y 2 y los aplicamos al caso, con datos sintéticos.

Agenda de la clase

Momento	Actividad	Evidencia
Marco y herramientas	Cómo se gestiona un proyecto (CRISP-DM) y para qué sirve cada librería	Orden del ciclo
Activación	Recuperar dos decisiones de las clases online	Supuestos iniciales
Demostración comentada	Cargar, inspeccionar y limpiar, con decisiones documentadas	Registro de decisiones
Práctica guiada	Tabla de auditoría y dos decisiones en pandas	Resultado intermedio controlado
Puesta en común	Comparar dos abordajes y corregir un error	Diferencia explicada
Pausa	Decisión confirmada, duda y riesgo	Pregunta registrada
Desafío por equipos	Mini análisis del abandono por canal y segmento	Producto del equipo
Defensa y revisión cruzada	Presentaciones breves y preguntas	Feedback de pares
Cierre	Volver a la pregunta y entregar	Ticket de salida

Cinco clases, un solo proyecto

Integrar el recorrido en un proyecto de NovaRetail y defenderlo en la clase 5.

LAS CINCO CLASES EN VIVO

1 HOY

Python aplicado

2

Machine Learning
aplicado

3

Deep Learning y
modelos avanzados

4

De modelo a
producción

5

Proyecto final y cierre

Hoy aportamos: notebook reproducible: auditoría, dos variables, hallazgo y límite.

Qué se entrega

1 Presentación ejecutiva con la recomendación

2 Repositorio o notebook reproducible

3 Ficha de modelo

4 Matriz de riesgos

5 Recomendación, con sus condiciones

6 Plan de monitoreo

7 Defensa de 7 min y 5 min de preguntas

El proyecto sigue cuatro etapas: definición, dataset, modelo y presentación final.

Un proyecto de datos es un ciclo

1 Negocio

¿Qué decisión se toma y cómo se sabrá que salió bien?

2 Datos

¿Qué datos hay, de dónde vienen y qué calidad tienen?

3 Preparación

Limpiar, unir y crear variables, con cada decisión documentada.

4 Modelado

Probar técnicas contra una línea base.

5 Evaluación

¿Responde la decisión? ¿Con qué error y a qué costo?

6 Despliegue

Usarlo, monitorearlo y decidir cuándo volver a empezar.

No es una fila de pasos: se vuelve atrás cuando aparece nueva evidencia.

Un proyecto sólido conecta **cuatro piezas**

1

Alcance

Qué decisión, para quién y qué significa que salió bien.

2

Datos

Qué población, qué período y qué calidad.

3

Modelo

Qué se compara contra qué y por qué se eligió.

4

Defensa

Qué se afirma, con qué evidencia y qué no.

Antes de usar la herramienta, explicá qué cambia en la decisión.

Cuatro librerías, cuatro preguntas de negocio

Librería	Para qué sirve	Pregunta de negocio	En NovaRetail
NumPy	Cálculo sobre arreglos; semillas y datos simulados	¿Puedo repetir el cálculo y obtener lo mismo?	Datos sintéticos con semilla 42
pandas	Leer, limpiar, unir y agrupar tablas	¿Qué pasó y qué calidad tienen los datos?	Ticket por canal; abandono por segmento
scikit-learn	Preparar, modelar y evaluar	¿Qué clientes tienen más riesgo y qué tan confiable es la predicción?	Modelo de abandono (clase 2)
matplotlib / seaborn	Gráficos	¿Cómo comunico el hallazgo para que alguien decida?	Mapa de calor del abandono

Una herramienta se elige por la pregunta que responde, no por la moda.

Lo que da cada herramienta

Confianza en el dato

NumPy · pandas

- Qué pasó
- Con qué calidad
- Se puede repetir

Confianza en la predicción

scikit-learn

- Contra qué se compara
- Qué tan buena es
- Cuánto cuesta equivocarse

Capacidad de decidir

matplotlib · seaborn

- Un hallazgo claro
- Para quien tiene que actuar
- Con su límite

Con este kit vamos al caso: NovaRetail y tres números distintos para un mismo pedido.

El caso: NovaRetail

Quién es

Retailer ficticio con clientes en web, app y tienda.

Qué hay

Tablas de clientes y de transacciones, generadas desde código.

Qué se predice

abandono_90d o CHURN: si el cliente se fue en los 90 días siguientes.

Qué hay que cuidar

Repetidos, faltantes, valores imposibles y una variable que filtra el resultado.

Una pregunta, varias decisiones

¿Qué controles hacen falta antes de afirmar que un grupo de clientes presenta mayor riesgo de abandono?

Para responderla vamos a decidir:

Claves y duplicados

Faltantes

Valores imposibles

Fuga y sesgo

Tres números para un mismo pedido

Fecha distinta

Una persona filtró el trimestre por fecha de compra y otra por fecha de facturación.

Devoluciones

Una las excluyó y otra no.

Muestra sin registro

Una trabajó con una muestra aleatoria y no dejó anotado cómo la generó.

Entorno sin anotar

Ninguna dejó escrito qué bibliotecas ni qué archivo exacto usó.

Los cinco controles, antes de calcular

Control	Qué mirar
1 · Forma	¿Las filas coinciden con lo esperado? Si faltan filas, algo se perdió.
2 · Tipos	¿La fecha es fecha y el monto es número? Un monto leído como texto rompe cualquier promedio.
3 · Nulos	¿Hay faltantes donde no debería haberlos?
4 · Unicidad	¿La clave es realmente única? Los duplicados silenciosos inflan todos los agregados.
5 · Rangos	¿Montos negativos? ¿Un canal que no existe en el negocio?

*No se ejecuta ningún cálculo de negocio antes de pasar estos cinco controles.
Antes, semilla fija y versiones impresas.*

Antes de empezar: pensar

¿Qué decisión debería poder tomar al final de la clase y qué dato no alcanzaría para sostenerla?

1

Individual

Dos minutos, por escrito.

2

En parejas

Contrastan sus respuestas.

3

Al grupo

Tres respuestas,
vinculadas con las clases
online (clases 1 y 2).

Registramos los desacuerdos; todavía no los resolvemos.

Lo que traemos del recorrido online

Flujo de un proyecto

De la pregunta de negocio a la decisión:
cada etapa deja evidencia.

Lectura y exploración

Forma, tipos, claves, faltantes y
distribución del objetivo.

Limpieza y transformación

Pandas y NumPy: una decisión por
columna, documentada.

Variables y exploración

Feature engineering con criterio y una
visualización que responda.

La ficha de evidencia

1

Decisión

¿Qué
decisión
habilita?

2

Población

Quiénes, qué
período y
qué objetivo.

3

Procedimiento

Qué se hizo,
en orden.

4

Resultado

El hallazgo,
en una frase.

5

Validación

Cómo se
comprobó.

6

Límite

Qué no se
puede
afirmar.

Seis campos que se completan al cerrar cada ejercicio.

Primer vistazo al dataset

```
import pandas as pd
df = cargar() # datos sintéticos de NovaRetail

df.shape           # forma
df.dtypes          # tipos
df.id_cliente.is_unique # ¿clave única?
df.isna().mean()   # faltantes
df['abandono_90d'].mean() # tasa base
```

1 Forma y tipos

2 Claves y duplicados

3 Faltantes por columna

4 Distribución del objetivo

Todo se muestra en VS Code, en el notebook de la clase.

Predecí antes de ejecutar

1

¿Clave única?

¿id_cliente identifica a un cliente por fila?

2

dropna()

¿Cuántas filas sobreviven a borrar todos los faltantes?

3

La tasa de abandono

¿Qué pasa con ella en las filas que quedan?

Primero predecimos, después ejecutamos y comparamos.

Una limpieza incorrecta

Tabla	Filas	Tasa de abandono
Cruda (con duplicados)	8.060	14,3 %
dropna() sobre todas las columnas	743 (9 %)	100 %
dropna() sin motivo_baja	6.606	11,2 %
Decisiones documentadas por columna	8.000	14,3 %

Dataset de práctica. La limpieza correcta conserva el universo y la tasa.

Una decisión por columna

Columna	Defecto	Decisión	Validación
id_cliente	repetido	drop_duplicates	is_unique y 8.000 clientes
edad	valores imposibles	fuera de 18–100 → faltante	cuántas filas cambian
region	faltante	categoría «Sin dato»	no se pierden filas
satisfaccion	faltante informativo	indicador, sin rellenar	abandono por grupo
motivo_baja	posterior al evento	no se usa	AUC aislado cercano a 1

Los faltantes de satisfacción abandonan 33 %, contra 11 % de quienes respondieron.

Del script suelto al **pipeline reproducible**

```
def preparar(df):  
    d = df.drop_duplicates('id_cliente').copy()  
    d['edad'] = d['edad'].where(d.edad.between(18, 100))  
    d['region'] = d['region'].fillna('Sin dato')  
    d['sat_falta'] = d.satisfaccion.isna().astype(int)  
    assert d['id_cliente'].is_unique  
    assert abs(d[TARGET].mean() - base) < 1e-9  
    return d
```

1

Una función, no un script suelto

2

Los controles viven en el código

3

Se corre desde los datos originales

Reproducible: cualquiera llega al mismo resultado.

Primer desafío: **manos a la obra**

Construir una tabla de auditoría (variable, defecto, decisión, validación) e implementar dos decisiones en pandas sin alterar el universo.

LA TABLA LLEVA

Variable

Defecto

Decisión

Validación

Pausa 1

Cada equipo muestra un control antes de seguir.

Pausa 2

Intercambian con otro equipo y piden una observación concreta.

Comparamos decisiones, no solo resultados

1

Dos soluciones distintas

Indicador de faltante contra imputación con la mediana.

2

Una pregunta

¿Qué cambia en la recomendación y qué evidencia decide?

3

Corregir un paso

Solo el que cambia la conclusión; el grupo anticipa el efecto.

Mostramos el error sin ridiculizar el intento.

Errores frecuentes y cómo evitarlos

Error	Efecto	Cómo se evita
Borrar filas sin medir impacto	Se pierde una parte no aleatoria de los clientes	Comparar filas y tasa antes y después
Imputar antes de separar entrenamiento y prueba	La prueba influye en el modelo (fuga)	Imputar dentro del Pipeline, con entrenamiento
Confundir correlación con causa	Web parece culpable; parte es composición	Controlar por segmento y mostrar tamaños
Usar el target para construir una variable	Métrica inflada que no existe en producción	Revisar disponibilidad y AUC aislado

Ante un error: primero se predice su impacto, después se compara con una salida controlada.

Tres cosas antes de salir

Cada equipo deja escrito qué confirmó, qué duda tiene y qué riesgo ve.

1

Una decisión confirmada

Algo que ya está firme.

2

Una duda

Se agrupan para empezar el desafío.

3

Un riesgo

Lo que podría salir mal.

El caso principal

CONSIGNA

Preparar un mini análisis:

- 1. Abandono por canal y segmento**
- 2. Dos variables justificadas**
- 3. Un hallazgo con su limitación.**



Si terminan antes:

Una visualización que muestre el tamaño de cada grupo.

ROLES ROTATIVOS

Conduce

ordena el trabajo

Implementa

escribe el código

Valida

controla el resultado

Presenta

cuenta la decisión

Cinco preguntas **que te voy a hacer**

1

**¿Qué decisión
habilita?**

2

**¿Cuál es la
población y el
período?**

3

**¿Cómo evitaron
fuga o sesgo?**

4

¿Qué validaron?

5

**¿Qué no pueden
afirmar?**

Si no pueden responder una, esa es su primera pregunta abierta.

Cómo se reconoce un resultado logrado



Responde la pregunta y la decisión definidas



Declara población, período, granularidad y objetivo



Conserva una ruta reproducible, de los datos a la conclusión



Compara contra una referencia y usa métricas acordes al costo del error



Incluye controles de calidad, fuga, sesgo y generalización



Separa evidencia, interpretación y recomendación



Documenta al menos una limitación y un siguiente paso

No existe una única implementación correcta.

Presentar y ser revisado

1

Presenta

Cuatro minutos para presentar.

2

Pregunta el equipo revisor

Una técnica, una de negocio y una sobre riesgo.

3

Devuelve por escrito

Una fortaleza, una brecha prioritaria y una mejora verificable.

Tres minutos de preguntas. Lo que se pide tiene que poder verificarse.

De la respuesta a la evidencia

1

Volvemos a la pregunta

Una respuesta de una frase, con su evidencia.

2

Acordamos el criterio

Qué hace que este trabajo esté bien hecho.

3

Ticket individual

Qué repetiría, qué verificaría y qué no llevaría todavía a producción.

Hacia la próxima clase

Ya tenemos datos auditados y variables con criterio.
¿Qué modelo y qué umbral conviene usar?

Partición estratificada

Pipeline

Métricas

Umbral

Clase 2: comparar modelos de clasificación según el costo del error.

Key Takeaways

1

Controlar antes de afirmar

Un grupo de riesgo exige controles.

2

Documentar cada decisión

Por columna, con su validación.

3

Medir el impacto de limpiar

Filas y tasa, antes y después.

4

Cuidar el target

Ninguna variable puede conocerse después.

Qué repetiría, qué verificaría y qué no llevaría todavía a producción.

PREGUNTAS Y RESPUESTAS

Q&A

¿Qué dudas, casos o ideas quedaron?

¡Muchas gracias!

Laura Sol Franco · Digital House